

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

7. Recherche de composantes principales

Définition 1

A chaque axe principal (factoriel) (Δu_j) est associé une variable C^j appelée composante principale de dimension m .

$$(\Delta u_j) \longrightarrow C^j \text{ pour tout } j.$$

Définition 2

Une composante principale n'est que le vecteur constitué des projections des individus sur l'axe principal associé à cette nouvelle variable.

$$C^1 = (x_1, x_2, \dots, x_i, \dots, x_m)t$$

Illustrons ces définitions par des exemples explicites et voir comment calculer les C.P.

Exemple

La composante C^1 représente le vecteur des coordonnées des projections des m individus sur le 1^{er} axe.

C'est-à-dire :

$$C^1 = (x_1, x_2, \dots, x_i, \dots, x_m)t.$$

Où x_i est la projection de l'individu X_i sur le premier axe, pour $i = 1, 2, \dots, m$.

Comme $x_i = \langle X_i, u_1 \rangle$ pour tout $i = 1, 2, \dots, m$, alors :

$$C^1 = {}^t(\langle X_1, u_1 \rangle, \dots, \langle X_i, u_1 \rangle, \dots, \langle X_m, u_1 \rangle).$$

Mais u_1 est un vecteur de $\mathcal{R}^n$ (car il a été déterminé à partir de la matrice de corrélation), alors en notant : $u_1 = {}^t(u_{11}, u_{21}, \dots, u_{n1})$, nous avons :

$$x_i = \langle X_i, u_1 \rangle = \sum_{j=1}^n x_i^j \cdot u_{j1} \quad \text{pour tout } i = 1, 2, \dots, m.$$

Où $X_i = {}^t(x_i^1, x_i^2, \dots, x_i^j, \dots, x_i^n) \in \mathcal{R}^n$ est le $i^{\text{ème}}$ individu.

Ainsi, la composante C^1 s'écrit explicitement comme suit :

$$\begin{aligned} x_1 &= \langle X_1, u_1 \rangle = \sum_{j=1}^n x_1^j \cdot u_{j1} \\ x_2 &= \langle X_2, u_1 \rangle = \sum_{j=1}^n x_2^j \cdot u_{j1} \\ &\vdots \\ x_m &= \langle X_m, u_1 \rangle = \sum_{j=1}^n x_m^j \cdot u_{j1} \end{aligned}$$

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

C'est-à-dire :

$$C^1 = \begin{pmatrix} \sum_{j=1}^n x_1^j \cdot u_{j1} \\ \vdots \\ \sum_{j=1}^n x_i^j \cdot u_{j1} \\ \vdots \\ \sum_{j=1}^n x_m^j \cdot u_{j1} \end{pmatrix} = \begin{pmatrix} x_1^1 \cdot u_{11} + x_1^2 \cdot u_{21} + \dots + x_1^n \cdot u_{n1} \\ \vdots \\ x_i^1 \cdot u_{11} + x_i^2 \cdot u_{21} + \dots + x_i^n \cdot u_{n1} \\ \vdots \\ x_m^1 \cdot u_{11} + x_m^2 \cdot u_{21} + \dots + x_m^n \cdot u_{n1} \end{pmatrix}$$

Que nous pouvons écrire sous la forme suivante :

$$C^1 = \begin{pmatrix} \sum_{j=1}^n x_1^j \cdot u_{j1} \\ \vdots \\ \sum_{j=1}^n x_i^j \cdot u_{j1} \\ \vdots \\ \sum_{j=1}^n x_m^j \cdot u_{j1} \end{pmatrix} = u_{11} \cdot \begin{pmatrix} x_1^1 \\ \vdots \\ x_i^1 \\ \vdots \\ x_m^1 \end{pmatrix} + u_{21} \cdot \begin{pmatrix} x_1^2 \\ \vdots \\ x_i^2 \\ \vdots \\ x_m^2 \end{pmatrix} + \dots + u_{n1} \cdot \begin{pmatrix} x_1^n \\ \vdots \\ x_i^n \\ \vdots \\ x_m^n \end{pmatrix}.$$

Autrement dit

$$C^1 = u_{11} \cdot X^1 + u_{21} \cdot X^2 + \dots + u_{n1} \cdot X^n \quad \text{c'est-à-dire} \quad C^1 = \sum_{j=1}^n u_{j1} \cdot X^j = X \cdot u_1.$$

Car : $X = (X_1 \ X_2 \ \dots \ X_n)$

De même, la composante C^2 est le vecteur des coordonnées des projections des m individus sur le 2^{ème} axe.

$$C^2 = \langle \langle X_1, u_2 \rangle, \dots, \langle X_i, u_2 \rangle, \dots, \langle X_m, u_2 \rangle \rangle = \sum_{j=1}^n u_{j2} \cdot X^j = X \cdot u_2.$$

$$C^2 = u_{12} \cdot X^1 + u_{22} \cdot X^2 + \dots + u_{n2} \cdot X^n \quad \text{C'est adire :} \quad C^2 = \sum_{j=1}^n u_{j2} \cdot X^j = X \cdot u_2.$$

Ainsi, nous remarquons que

les composantes principales sont des combinaisons linéaires des variables initiales.

7.1 Propriétés des composantes principales

Les composantes principales vérifient les propriétés suivantes :

- 1) La variance d'une composante principale est égale à l'inertie portée par l'axe principal qui lui est associé c'est à dire pour chaque composante C^i ,

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

$$\text{Var}(C^i) = \lambda_i, \quad i = 1, 2, \dots, q.$$

Où q représente la dimension du sous espace ajustant le nuage de points.

2) Les composantes principales sont **non corrélées deux à deux** c'est-à-dire les axes associés sont orthogonaux deux à deux.

$$\text{Cov}(C^i, C^j) = 0 \quad \text{pour tout } i \text{ et } j \text{ dans } \{1, 2, \dots, q\}.$$

7.2 Représentation des individus

N'oublions pas que notre but est de passer de l'espace $\mathbb{R}^n$ vers l'espace $\mathbb{R}^q$ de dimension faible par rapport à celle d'origine ($q \ll n$) afin que nous puissions visualiser les données (ici, il s'agit des individus).

Par conséquent représenter les individus revient à les représenter dans l'espace $\mathbb{R}^q$.

Donc, il est plus intéressant de prendre $q = 1, 2$ et de préférence qu'il soit un sous espace de dimension 2 (plan) c'est-à-dire $q = 2$ car même pour $q = 3$, la visualisation restera toujours difficile.

Exemple

Pour éclaircir cette idée de représentation d'individus, supposons par exemple que $q = 2$. Alors, il faut représenter les individus dans l'espace (C^1, C^2) avec C^1, C^2 sont les deux nouvelles variables (composantes principales).

Soit C^j la $j^{\text{ème}}$ composante principale, $j = 1, 2$ dans notre cas.

Par définition, C^j est constituée des m coordonnées des individus sur la $j^{\text{ème}}$ composante c'est-à-dire le $j^{\text{ème}}$ axe principal.

Posons : $C^j = {}^t(c_1^j, c_2^j, \dots, c_m^j)$ pour $j = 1, 2$,

Alors :

Chaque individu X_i aura (c_i^1, c_i^2) comme coordonnées dans le nouveau plan. Voir l'illustration graphique ci-dessous (figure 5).

D'après le paragraphe précédent,

$$C^1 = X \cdot u_1, \quad C^2 = X \cdot u_2.$$

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

Avec : $c_i^1 = X_i \cdot u_1$ et $c_i^2 = X_i \cdot u_2$ pour tout $i = 1, 2, \dots, m$.

Mais dans le cas d'une **ACP normée**, bien-sur nous prenons : $C^1 = Z \cdot u_1$ et $C^2 = Z \cdot u_2$.




Figure 5. Projection d'un point sur un plan.

D'une manière générale le choix du nouveau sous-espace c'est-à-dire le choix de q dépend aussi du problème à résoudre ou à modéliser et la précision à exiger.

Question

Comment et quel est le nombre de composantes principale (d'axes) q à retenir pour avoir une approximation satisfaisante?.

Réponse

La réponse à la question posée est liée d'une manière directe à la notion de l'inertie comme nous allons le voir dans ce qui suit.

8. Nombres d'axes

Le choix du nombre de composantes suffisamment représentatives est lié à la notion de l'inertie exprimée par le sous espace principal.

Définition

Nous appelons **pourcentage d'inertie reproduite** ou **expliquée** par le sous espace de $\dim = q$, le rapport :

$$\sum_{i=1}^q \lambda_i / \sum_{i=1}^n \lambda_i. \quad (4).$$

Cas particulier

Le rapport défini ci-dessus nous permet donc de mesurer **la part d'inertie expliquée** par **chaque axe**. Cette part est exprimée en pourcentage et elle est donnée par le rapport :

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

$$\lambda_i / \sum_{i=1}^n \lambda_i \text{ pour tout } i = 1, 2, \dots, q.$$

Où λ_i représente la valeur propre associé au $i^{\text{ème}}$ axe, $i = 1, 2, \dots, q$.

Sachant que par définition l'**inertie totale** (I_g) est la **somme des variances** c'est-à-dire :

$$I_g = \sum_{i=1}^n \text{var}(X^i) = \text{Trace}(V).$$

Alors dans le cas où les données sont centrées-réduites, l'inertie totale est égale à n car la variance de chaque variable transformée est égale à 1.

Donc

$$I_g = n = \text{Trace}(R).$$

Par conséquent, le rapport (4) devient

$$\sum_{i=1}^q \lambda_i / n \text{ pour tout } q \geq 1.$$

Par suite le taux d'inertie expliqué par chaque axe est donné par :

$$\lambda_i / n \text{ pour } i = 1, 2, \dots, q.$$

Basé sur ces explications d'inerties, nous définissons maintenant ci-dessous les critères de base les plus utilisés pour choisir le nombre d'axes à retenir. Ces critères se classifient en deux classes :

i) Critères globaux

Quelques critères simples du choix de la dimension de l'espace de projection sont :

- 1) Pourcentage d'inertie souhaité a priori. Il s'agit de fixer dès le départ le taux souhaité par l'utilisateur. Généralement, nous choisissons ce taux **supérieur à 80%** (même par fois à 70 %).
- 2) Retenir que les axes principaux associés aux valeurs propres **supérieures à 1**. Il s'agit du critère **de Kaiser-Guttman**.
- 3) Histogramme des valeurs propres ou bien critère du **coude** de **Cattell**, nous présentons les

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

valeurs propres dans un plan selon leurs valeurs dans un ordre décroissant de la plus grande vers la plus petite. Ensuite nous sélectionnons les valeurs propres les plus importantes, celles qui précèdent le point qui représente un coude dans le graphe comme c'est illustré dans la figure 6.

Dans le graphe de cette figure, nous choisissons les valeurs propres : $\lambda_3, \lambda_5, \lambda_2$.




Figure 6. Illustration du critère de Cattell.




Figure 7. Illustration du critère de Cattell.

Remarque

La question qui se pose est : faut-il toujours ignorer la valeur qui correspond au coude ou pas ?. En général, tout dépendra de cette valeur, si elle est faible, nous l'ignorons. Mais parfois, ce coude peut se présenter à la deuxième position, alors de préférence sélectionner la valeur propre correspondante pour avoir un sous espace de projection de dimension 2 c'est-à-dire avoir un plan.

ii) Critères de qualité

D'autres critères sont présentés dans la littérature, ils sont basés sur la qualité de la représentation des individus.

1) Qualité de la représentation d'individu. La qualité de la représentation d'un individu X_i pour $i = 1, 2, \dots, m$ sur un sous espace de dimension q est donnée par le rapport suivant :

$$\phi_i^q = \sum_{j=1}^q (c_i^j)^2 / \|X_i\|^2. \quad (5)$$

Cas particulier

Pour mieux illustrer cette idée de qualité, prenons $q = 1$ et soit X_i un individu quelconque du nuage des individus. Alors : la projection de X_i sur le sous espace de dimension 1, (Δu_1) a comme coordonnée c_i^1 .

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

Soit θ l'angle inscrit entre le vecteur $(\vec{OX}_i)$ et la droite (Δu_1) , alors :

$$(\cos(\theta))^2 = (c_i^1)^2 / \|X_i\|^2.$$




Figure 8. Illustration de ϕ_1^1 .

Du rapport (5), nous avons : $\phi_1^1 = (\cos(\theta))^2$

Donc dans le cas où le sous espace de projection est un seul axe, la qualité de la représentation d'un individu quelconque sur cet axe n'est que le carré du cosinus de l'angle entre le vecteur $(\vec{OX}_i)$ et l'axe de projection. Par conséquent, plus que $(\cos(\theta))^2$ est proche de 1 meilleure est la qualité de la représentation de X_i sur l'axe (Δu_1) .

Remarque 1

D'une manière générale, cette qualité de représentation ϕ_i^q est dite la contribution relative de l'individu X_i sur le sous espace de projection de dimension q .

Remarque 2

D'après l'exemple explicatif ci-dessus, nous pouvons dire que ϕ_i^q n'est que la **somme des carrés des cosinus des angles** inscrits entre $(\vec{OX}_i)$ et ses projections sur les axes de l'espace de projection de dimension q .

2) Contribution de l'individu Ce critère qui représente la contribution de chaque individu X_i , $i = 1, 2, \dots, m$ à l'inertie du $j^{\text{ème}}$ axe (Δu_j) pour $j = 1, 2, \dots, q$ est donné par le rapport :

$$\gamma_i^j = \frac{1}{m} \cdot (c_i^j)^2 / \lambda_j. \quad (6)$$

Ce rapport est noté aussi par $ctr(i, j)$.

En effet, Nous savons bien que l'inertie du $j^{\text{ème}}$ l'axe est donnée par :

$$I((\Delta u_j)) = \lambda_j \text{ pour } j = 1, 2, \dots, q.$$

D'autre part, $\text{var}(C^j) = \lambda_j$ pour tout $j = 1, 2, \dots, q$. Alors :

$$\text{var}(C^j) = \lambda_j \Leftrightarrow \frac{1}{m} \sum_{i=1}^m (c_i^j)^2 = \lambda_j \text{ pour tout } j = 1, 2, \dots, q.$$

M1 : MIV
Enseignant : N. Laiche

Analyse en composantes principales

C'est-à-dire

$$\frac{1}{m}(c_1^j)^2 + \frac{1}{m}(c_2^j)^2 + \dots + \frac{1}{m}(c_i^j)^2 + \dots + \frac{1}{m}(c_m^j)^2 = \lambda_j$$

Ce qui est équivalent à

$$\frac{1}{m \cdot \lambda_j}(c_1^j)^2 + \frac{1}{m \cdot \lambda_j}(c_2^j)^2 + \dots + \frac{1}{m \cdot \lambda_j}(c_i^j)^2 + \dots + \frac{1}{m \cdot \lambda_j}(c_m^j)^2 = 1.$$

C'est-à-dire

$$\frac{1}{m \cdot \lambda_j}[(c_1^j)^2 + (c_2^j)^2 + \dots + (c_m^j)^2] = \frac{1}{m \cdot \lambda_j} \sum_{l=1}^m (c_l^j)^2 = 1$$

Ce qui est équivalent à

$$\sum_{l=1}^m \frac{(1/m) \cdot (c_l^j)^2}{\lambda_j} = 1$$

D'où, en termes de pourcentages, l'inertie du $j^{\text{ème}}$ axe vérifie

$$\sum_{l=1}^m \frac{(1/m) \cdot (c_l^j)^2}{\lambda_j} = 100\%.$$

Ce qui nous conduit à conclure que chaque facteur :

$$\frac{1}{m} \cdot (c_l^j)^2 / \lambda_j \text{ pour } l = 1, 2, \dots, m$$

n'est que **la contribution du $l^{\text{ème}}$ individu à l'inertie du $j^{\text{ème}}$ axe.**

Remarque

Cette contribution d'un individu X_i , $i = 1, 2, \dots, m$ à l'inertie du $j^{\text{ème}}$ axe (Δu_j) pour $j = 1, 2, \dots, q$ est dite contribution absolue de l'individu X_i à l'inertie du $j^{\text{ème}}$ axe.

Remarque

La même procédure suivie pour analyser le nuage des individus sera appliquée sur le nuage des variables.

Exemple