Faculté d'Informatique
Département d'IA et SD
Enseignant : N. Laiche

Analyse factorielle des correspondance AFC

Corrigé de la série 3

Exercice 1

$$K = \begin{pmatrix} 13 & 2 & 5 \\ 20 & 2 & 8 \\ 10 & 5 & 5 \\ 7 & 1 & 22 \end{pmatrix}$$ est de type (4, 3) : X a 4 modalités et

Y a 3 modalités et n= !!!

1) De la matrice de contingence, nous en déduisons que le nombre d'individus est donné par :

$$n = \sum_{i,j} k_{ij} = 100.$$ = 13+2+5+20+…..+22.

Par suite, la matrice des fréquences relatives est donnée par :

$$F = \left(\begin{array}{ccc|c} 0.13 & 0.02 & 0.05 & 1/5 \\ 0.2 & 0.02 & 0.08 & 3/10 \\ 0.1 & 0.05 & 0.05 & 1/5 \\ 0.07 & 0.01 & 0.22 & 3/10 \\ \hline 5/10 & 1/10 & 2/5 & 1 \end{array}\right).$$ $f_{ij} = k_{ij}/100.$

Avec :
Les fréquences marginales sont :

$$f_{i+} = \sum_{l=1}^{q=3} f_{il}.$$

Pour : i =1 à 4, nous avons : 1/5, 3/10, 1/5, 3/10
Et les

$$f_{+j} = \sum_{l=1}^{p} f_{lj}.$$

Pour : j = 1 à 3, nous avons : 5/10, 1/10, 2/5.

2) De la matrice F, nous définissons deux matrices comme suit :

i) La matrice des profils-lignes est donnée par :

Analyse factorielle des correspondance AFC

$$X_L = \begin{pmatrix} 13/20 & 1/10 & 1/4 \\ 2/3 & 1/15 & 4/15 \\ 1/2 & 1/4 & 1/4 \\ 7/30 & 1/30 & 11/15 \end{pmatrix}$$

$$X_L = \begin{pmatrix} \frac{f_{11}}{f_{1+}} & \frac{f_{12}}{f_{1+}} & \frac{f_{13}}{f_{1+}} \\ \frac{f_{21}}{f_{2+}} & \frac{f_{22}}{f_{2+}} & \frac{f_{23}}{f_{2+}} \\ \frac{f_{31}}{f_{3+}} & \frac{f_{32}}{f_{3+}} & \frac{f_{33}}{f_{3+}} \\ \frac{f_{41}}{f_{4+}} & \frac{f_{42}}{f_{4+}} & \frac{f_{43}}{f_{4+}} \end{pmatrix}$$

ii) La matrice des profils-colonnes est donnée par :

$$X_C = \begin{pmatrix} \frac{f_{11}}{f_{+1}} & \frac{f_{12}}{f_{+2}} & \frac{f_{13}}{f_{+3}} \\ \frac{f_{21}}{f_{+1}} & \frac{f_{22}}{f_{+2}} & \frac{f_{23}}{f_{+3}} \\ \frac{f_{31}}{f_{+1}} & \frac{f_{32}}{f_{+2}} & \frac{f_{33}}{f_{+3}} \\ \frac{f_{41}}{f_{+1}} & \frac{f_{42}}{f_{+2}} & \frac{f_{43}}{f_{+3}} \end{pmatrix} \qquad X_C = \begin{pmatrix} 13/50 & 1 & 5/8 \\ 2/5 & 10/15 & 2/3 \\ 1/5 & 5/2 & 5/8 \\ 7/50 & 1/3 & 11/6 \end{pmatrix}$$

3) Le nuage des profils-lignes transformées est défini par :

$$N'(I) = \{((X_L')_i, f_{i+}), i = 1,2,3,4\} \subset \Re^3.$$

Où. pour $i = 1,2,3,4$:

$$(X_L')_i = \left(\frac{f_{i1}}{f_{i+} \cdot \sqrt{f_{+1}}}, \quad \frac{f_{i2}}{f_{i+} \cdot \sqrt{f_{+2}}}, \quad \frac{f_{i3}}{f_{i+} \cdot \sqrt{f_{+3}}} \right).$$

Après calculs, nous trouvons :

$$X_L' = \begin{pmatrix} \frac{13 \cdot \sqrt{2}}{20} & \frac{\sqrt{10}}{20} & \frac{\sqrt{10}}{8} \\ \frac{2\sqrt{2}}{3} & \frac{\sqrt{10}}{15} & \frac{2\sqrt{10}}{15} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{10}}{4} & \frac{\sqrt{10}}{8} \\ \frac{7\sqrt{2}}{30} & \frac{\sqrt{10}}{30} & \frac{11\sqrt{10}}{30} \end{pmatrix}. = \text{X}_\text{L} \text{ transformée}$$

Analyse factorielle des correspondance AFC

4) La **proximité** entre les ***modalités de la première variable***

Ou bien

Entre celles de la ***deuxième variable***

se fait moyennant la **distance chi-deux.**

Mais

Après la ***transformation des matrices des profils- lignes ou colonnes***, nous appliquons la **distance Euclidienne**.

Ainsi, par exemple la proximité entre les modalités 1 et 3 de la première valable est donnée par :

$$d^2\left((X_L')_1,(X_L')_3\right) = \left\|(X_L')_1 - (X_L')_3\right\|^2.$$

$$= \left(\frac{13\cdot\sqrt{2}}{20} - \frac{\sqrt{2}}{2}\right)^2 + \left(\frac{\sqrt{10}}{10} - \frac{\sqrt{10}}{4}\right)^2 + \left(\frac{\sqrt{10}}{8} - \frac{\sqrt{10}}{8}\right)^2.$$

=((13.rac(2)/20-rac(2)/2)^2/(5/10) + (***Proximité***)

$$X_L' = \begin{pmatrix} \frac{13\cdot\sqrt{2}}{20} & \frac{\sqrt{10}}{20} & \frac{\sqrt{10}}{8} \\ \frac{2\sqrt{2}}{3} & \frac{\sqrt{10}}{15} & \frac{2\sqrt{10}}{15} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{10}}{4} & \frac{\sqrt{10}}{8} \\ \frac{7\sqrt{2}}{30} & \frac{\sqrt{10}}{30} & \frac{11\sqrt{10}}{30} \end{pmatrix}.$$

D'où

$$d^2\left((X_L')_1,(X_L')_3\right) = \frac{27}{100} \text{ et donc } d\left((X_L')_1,(X_L')_3\right) = \frac{\sqrt{27}}{10} \approx 0.51961.$$

De même, nous calculons :

$$d^2\left((X_L')_2,(X_L')_3\right) = \frac{213}{288} \text{ et donc } d\left((X_L')_2,(X_L')_3\right) = \sqrt{\frac{213}{288}} \approx 0.85999.$$

D'une manière générale,

Analyse factorielle des correspondance AFC

$$d^2\left((X'_L)_i,(X'_L)_j\right)=\sum_{k=1}^{3}\left(l_{ik}-l_{jk}\right)^2 \text{ pour } i,j=1,2,3,4.$$

Où $\left(X'_L\right)_i=(l_{i1},l_{i2},l_{i3})$ et $\left(X'_L\right)_j=(l_{j1},l_{j2},l_{j3})$ pour $i,j=1,2,3,4$.

Exercice 2

De la matrice des données, le nombre des individus est égal à $n=\sum_{i,j}k_{ij}=12$.

1) Le tableau des fréquences relatives est donné par :

Partant de : $K=\begin{pmatrix}2 & 2\\ 1 & 3\\ 3 & 1\end{pmatrix}$.

Avec : Fij = kij/12

F =

X \ Y			f_{i+}
	1/6	1/6	1/3
	1/12	1/4	1/3
	1/4	1/12	1/3
f_{+j}	1/2	1/2	1

2) Le nuage des profils-lignes est défini par : $N(I)=\{((X_L)_i,f_{i+}),i=1,2,3\}\subset\Re^2$.
Où

$$(X_L)_i=\left(\frac{f_{i1}}{f_{i+}},\frac{f_{i2}}{f_{i+}}\right) \text{ pour } i=1,2,3.$$

Ce qui donne :

$$X_L=\begin{pmatrix}1/2 & 1/2\\ 1/4 & 3/4\\ 3/4 & 1/4\end{pmatrix}.$$

3) La matrice des variances-covariances est associée au nuage des profils transformé centré. Pour ce faire, calculons le vecteur profil moyen qui représente le centre de gravité du nuage et déterminons le nuage des profils transformé.
En effet,

$$g_I=\left(\sqrt{f_{+1}},\ \sqrt{f_{+2}}\right)\in\Re^2$$

Analyse factorielle des correspondance AFC

C'est-à-dire :

$$g_I = \left(\sqrt{\frac{1}{2}}, \sqrt{\frac{1}{2}}\right) = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$$

D'autre part, le ***profil-ligne transformé*** est défini par :

$$(X'_L)_i = \left(\frac{f_{i1}}{f_{i+}\cdot\sqrt{f_{+1}}}, \frac{f_{i2}}{f_{i+}\cdot\sqrt{f_{+2}}}\right) \text{ pour } i = 1,2,3.$$

Ce qui donne,

$$X_L = \begin{pmatrix} 1/2 & 1/2 \\ 1/4 & 3/4 \\ 3/4 & 1/4 \end{pmatrix} \qquad X'_L = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ \sqrt{2}/4 & 3\sqrt{2}/4 \\ 3\sqrt{2}/4 & \sqrt{2}/4 \end{pmatrix}.$$

Par suite, le ***nuage centré*** est défini par :

$$(Y_L)_i = \left(\frac{f_{i1}}{f_{i+}\cdot\sqrt{f_{+1}}} - \sqrt{f_{+1}}\ ,\ \frac{f_{i2}}{f_{i+}\cdot\sqrt{f_{+2}}} - \sqrt{f_{+2}}\right) \text{ pour } i = 1,2,3.$$

D'où

$$Y_L = \begin{pmatrix} 0 & 0 \\ -\sqrt{2}/4 & \sqrt{2}/4 \\ \sqrt{2}/4 & -\sqrt{2}/4 \end{pmatrix}.$$

Sachant que la matrice des poids associés aux profils-lignes est définie par :

$$D_I = \begin{pmatrix} f_{1+} & 0 & 0 \\ 0 & f_{2+} & 0 \\ 0 & 0 & f_{3+} \end{pmatrix} \text{ C'est à dire } D_I = \begin{pmatrix} 1/3 & 0 & 0 \\ 0 & 1/3 & 0 \\ 0 & 0 & 1/3 \end{pmatrix}.$$

Alors, la matrice d'inertie est définie par :

$$V_I = Y_L^t \cdot D_I \cdot Y_L$$

Nous remarquons que pour cet exercice, les fréquences marginales des profils-lignes c'est-à-dire les poids sont tous identiques et sont égales à 1/3 et par suite la matrice des poids n'est que :

$$D_I = \frac{1}{3}\cdot Id\ .$$

Par conséquent, la ***matrice d'inertie*** devient :

Analyse factorielle des correspondance AFC

$$V_I = \frac{1}{3} \cdot ({}^t Y_L \cdot Y_L).$$

D'où,

$$V_I = \begin{pmatrix} 1/12 & -1/12 \\ -1/12 & 1/12 \end{pmatrix}.$$

- Notons bien que v_{ij} n'est que la covariance entre deux variables (dans notre cas deux modalités), et dans le cas où $i = j$, il s'agit de la variance :

$$v_{ij} = cov(y_i, y_j) \quad \text{et} \quad v_{jj} = var(y_j) \quad \text{Pour } i, j = 1, 2, \ldots, q. \ (q = 2)$$

$$I = \sum_{j=1}^{q} v_{jj} = Trace\,(V_I)$$

Remarque

Notez bien donc que l'ajustement se fait sur la matrice d'inertie.

Remarque

Il y a un résultat intéressant qui nous fixe le nombre d'axes à fixer. Le nombre d'axes à retenir est inférieure ou égal au $Min(p, q) - 1$.

4) Pour ajuster le nuage des points, déterminons les valeurs propres qui reflètent la quantité d'information portée par les axes correspondant aux valeurs propres.
En effet,

$P_{V_I}(\lambda) = \det(V_I - \lambda \cdot Id) = 0$ est équivalent à

$$\begin{vmatrix} (1/12) - \lambda & -1/12 \\ -1/12 & (1/12) - \lambda \end{vmatrix} = \left(\frac{1}{12} - \lambda\right)^2 - \left(\frac{1}{12}\right)^2 = 0$$

Ce qui donne :

$$\lambda_1 = \frac{1}{12} - \frac{1}{12} = 0 \quad \text{et} \quad \lambda_2 = \frac{1}{12} + \frac{1}{12} = \frac{1}{6}.$$

De ces valeurs propres, nous pouvons exprimer le taux d'inertie expliqué par chaque axe :

Comme le 1èr axe correspond toujours à la plus grande valeur propre, alors le taux expliqué par le 1èr axe est défini par :

Analyse factorielle des correspondance AFC

$$T_1 = \frac{MAX|\lambda_i|}{Trace(V_I)} = \frac{1/6}{1/12+1/12} = \frac{1/6}{1/6} = 1.$$

C'est-à-dire

$$T_1 = 100\%.$$

Le taux expliqué par le deuxième axe correspondant à la deuxième valeur propre est donné par :

$$T_2 = \frac{\lambda_2}{Trace(V_I)} = \frac{0}{1/12+1/12} = 0.$$

C'est-à-dire

$$T_2 = 0\%.$$

Donc, toute ***l'information réside*** dans le 1èr axe. Ce qui explique que nous vous demandons de déterminer le sous espace de dimension 1 ajustant le nuage.
Pour déterminer cet axe, calculons le vecteur propre normé associé à la valeur propre : $\lambda_2 = \frac{1}{6}$.

Soit $u_1 = {}^t(x, y) \in \Re_*^2$ tel que : $V_I \cdot u_1 = \lambda_2 \cdot u_1$, alors :

$$\begin{cases} (1/12)\cdot x - (1/12)\cdot y = (1/6)\cdot x \\ (-1/12)\cdot x + (1/12)\cdot y = (1/6)\cdot y \end{cases} \Leftrightarrow \begin{cases} (-1/12)\cdot x = (1/12)\cdot y \\ (-1/12)\cdot x = (1/12)\cdot y \end{cases}.$$

Ce qui donne,

$$y = -x.$$

Par suite, le vecteur propre s'écrit comme suit, $u_1 = {}^t(x, -x)$ avec $x \in \Re^*$.

Soit alors, $u_1 = {}^t(1, -1)$. Par conséquent, l'axe représentatif est donné par le vecteur

$$u = {}^t(1/\sqrt{2},\ \ -1/\sqrt{2}).$$

5) La proximité entre les deux profils-lignes $(X_L)_1$ et $(X_L)_2$ est donnée comme suit :

$$d^2_{\chi^2}((X_L)_1, (X_L)_2) = \sum_{j=1}^{2} \frac{1}{f_{+j}} \left(\frac{f_{1j}}{f_{1+}} - \frac{f_{2j}}{f_{2+}} \right)^2$$

Ou bien, en utilisant la distance Euclidienne sur le nuage transformé :

$$d^2((X'_L)_1, (X'_L)_2) = \left(\frac{\sqrt{2}}{2} - \frac{\sqrt{2}}{4} \right)^2 + \left(\frac{\sqrt{2}}{2} - \frac{3\sqrt{2}}{4} \right)^2 = 1/4$$

Par suite, la proximité entre les deux premiers profils-lignes est 1/2.

Analyse factorielle des correspondance AFC

Déterminer les composantes principales associées au nuage des profils-lignes.

(Facteurs) lignes.

$$\phi_1 = (\phi_1^1,\ \phi_1^2,\ \phi_1^3)^t$$

Chaque φ_1^i représente la projection du i^{ème} profil-ligne sur le premier axe : u .

$$\phi_1^i = \langle (Y_L)_i, u \rangle$$

$$Y_L = \begin{pmatrix} 0 & 0 \\ -\sqrt{2}/4 & \sqrt{2}/4 \\ \sqrt{2}/4 & -\sqrt{2}/4 \end{pmatrix} * \mathrm{u}$$

Les profils-lignes	ϕ_1
PL_1	**0**
PL_2	½
PL_3	½

C1 = Y * u = (0, ½, ½) .

Visualisation : Sur un axe factoriel φ_1.

6) Grace aux relations de transition, nous pouvons définir les nouvelles variables du nuage des PC.
Comme nous avons fixé un plan, alors : pour i =1, 2, nous avons :

$$\psi_i^j = u_i \cdot \sqrt{\frac{\lambda}{f_{+i}}} \qquad \text{pour : } j = 1, 2, 3.$$

$$\psi_1 = u \cdot \sqrt{\frac{\lambda_u}{f_{+1}}}.$$

ψ_i^j représente la j^{ème} composante du i^{ème} facteur colonne.

$$\psi_1 = u \cdot \sqrt{\frac{1/6}{1/2}}. \qquad u = {}^t(1/\sqrt{2},\ \ -1/\sqrt{2})$$

Analyse factorielle des correspondance AFC

Les variables	ψ_1
PC_1	!
PC_2	!

Visualisation : pour les modalités de la 2ème variable

Relations reliant les ψ_1 en fonction de φ_1 !!!!!!