CORRIGÉ DÉTAILLÉ — TP 2 : ACP Normée

Analyse en Composantes Principales | M1 IA & SD | Février 2026

Introduction — Principe de l'ACP Normée

L'ACP (Analyse en Composantes Principales) est une méthode de réduction de dimension. L'ACP normée utilise la matrice de corrélation R (et non la matrice de covariance V) pour traiter des variables ayant des unités et des échelles différentes.

Étapes d'une ACP normée :

- 1. Standardiser les données : $Z = (X - \bar{x}) / \sigma$
- 2. Calculer la matrice de corrélation $R = (1/m)\, Z^t Z$
- 3. Diagonaliser R → valeurs propres λ et vecteurs propres U
- 4. Sélectionner les axes principaux à retenir
- 5. Projeter les individus : $C = Z \times U$

Question 1 — Valeurs propres et vecteurs propres

Matrice utilisée

Pour une ACP normée, on diagonalise la matrice de corrélation R (et non V). Cela permet de comparer des variables mesurées en unités différentes (taux de handball, de tennis…).

Code R :

```
# Standardisation des données
Z <- scale(X)       # centre ET réduit (divise par sd population)
# Ou manuellement :
Z <- sweep(X - apply(X,2,mean), 2, apply(X,2,sd), '/')

# Matrice de corrélation
m <- nrow(X)
R <- (1/m) * t(Z) %*% Z

# Décomposition en valeurs propres
result <- eigen(R)
valeurs_propres  <- result$values   # valeurs propres décroissantes
vecteurs_propres <- result$vectors  # colonnes = vecteurs propres
```

Valeurs propres

Axe	Valeur propre λ
F1	**3.4859**
F2	**1.4219**
F3	0.4728
F4	0.2943
F5	0.2187
F6	0.1064

Vecteurs propres (colonnes = axes factoriels)

Variable	F1	F2	F3	F4	F5	F6
H.Ball	-0.3767	-0.5533	-0.1686	-0.0664	0.0412	0.7194

B.Ball	-0.4219	0.0451	0.8757	-0.1854	-0.1369	0.0098
Tennis	-0.2684	0.6489	-0.2686	-0.5988	0.1501	0.2317
Gym	-0.4741	0.1349	-0.3014	0.2447	-0.7643	-0.1488
Natation	-0.4298	-0.4120	-0.2044	-0.3358	0.2910	-0.6374
F.Ball	-0.4457	0.2880	-0.0070	0.6557	0.5368	0.0163

→ Les colonnes du tableau sont les axes factoriels U1, U2, ..., U6. Les lignes correspondent aux variables originales. Les vecteurs propres sont orthonormés : $U_i^T U_j = \delta_{ij}$

Question 2 — Vérification du vecteur propre

Un vecteur v est vecteur propre de la matrice A associé à la valeur propre λ si et seulement si :

$A \cdot v = \lambda \cdot v$

Code R :

```
verif_vp <- function(A, v, lambda, tol=1e-8) {
  diff <- A %*% v - lambda * v
  return(all(abs(diff) < tol))
}

# Application sur le 1er vecteur propre :
v1 <- vecteurs_propres[, 1]
lambda1 <- valeurs_propres[1]
verif_vp(R, v1, lambda1)   # Doit retourner TRUE
```

Résultat : TRUE ✓

Vérification numérique :

- $R \cdot v_1$ = [−1.3131, −1.4705, −0.9355, −1.6526, −1.4983, −1.5537]
- $\lambda_1 \cdot v_1$ = [−1.3131, −1.4705, −0.9355, −1.6526, −1.4983, −1.5537] → Égalité vérifiée ✓

→ La tolérance tol est nécessaire car les calculs informatiques introduisent de petites erreurs d'arrondi flottant.

Question 3 — Graphe des valeurs propres (Éboulis)

Code R :

```
plot(1:p, valeurs_propres, type='b', pch=16, col='blue',
     xlab='Axes factoriels', ylab='Valeurs propres',
     main='Eboulis des valeurs propres', xaxt='n')
axis(1, at=1:p, labels=paste0('F',1:p))
abline(h=1, col='red', lty=2, lwd=2)  # Critère de Kaiser
text(1:p, valeurs_propres, round(valeurs_propres,3),
     pos=3, cex=0.8)
```

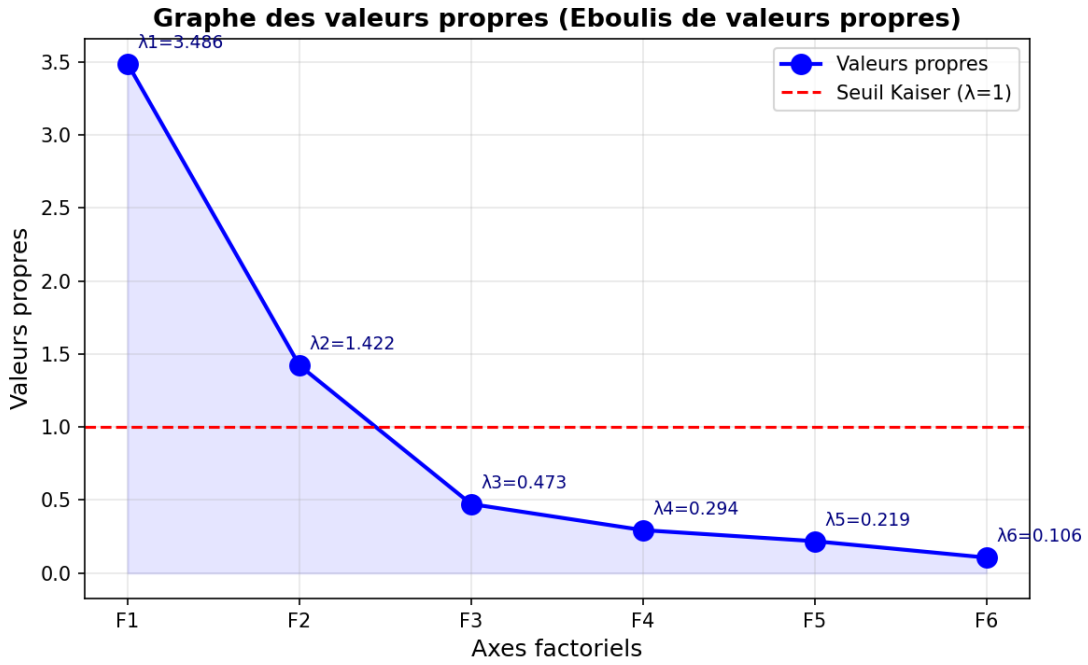

Analyse du graphe :

- La courbe chute brusquement après F2 (valeurs de 3.49 et 1.42), puis s'aplatit → c'est le "coude" caractéristique.
- Critère de Kaiser : on retient les axes avec λ > 1. Ici F1 (λ=3.49) et F2 (λ=1.42) dépassent le seuil.
- F3 à F6 ont des valeurs propres < 1 : ils n'apportent pas plus d'information qu'une variable originale standardisée.

→ L'éboulis (scree plot) est un outil graphique essentiel pour choisir le nombre d'axes à retenir.

Question 4 — Tableau des taux d'inertie

Code R :

```
p <- ncol(X)    # = 6 variables
taux       <- round(valeurs_propres / sum(valeurs_propres) * 100, 2)
taux_cum   <- round(cumsum(taux), 2)    # cumsum() = somme cumulée

tableau <- data.frame(
  Valeur_propre   = round(valeurs_propres, 4),
  Taux_inertie    = paste0(taux, ' %'),
  Taux_cumule     = paste0(taux_cum, ' %')
)
rownames(tableau) <- paste0('F', 1:p)
print(tableau)
```

Résultat :

Axe	Valeur propre λ	Taux d'inertie (%)	Taux cumulé (%)
F1	**3.4859**	**58.10%**	**58.10%**
F2	**1.4219**	**23.70%**	**81.80%**
F3	0.4728	7.88%	89.68%
F4	0.2943	4.91%	94.58%
F5	0.2187	3.64%	98.23%
F6	0.1064	1.77%	100.00%

(Les axes F1 et F2 en bleu sont ceux à retenir)

Rôle de cumsum() :

La fonction cumsum() (cumulative sum) calcule la somme cumulée des taux d'inertie. Elle permet de savoir combien d'information totale est capturée en gardant k axes. Par exemple, garder F1+F2 capture 81.80% de la variance totale.

Question 5 — Choix de la dimension du sous-espace factoriel

Critères pour choisir le nombre d'axes à retenir :

- Critère de Kaiser : retenir les axes avec λ > 1. → F1 et F2 (λ=3.49 et λ=1.42)
- Critère du coude (Cattel) : repérer la cassure dans l'éboulis. → Cassure nette après F2
- Critère du taux cumulé : retenir suffisamment pour expliquer ≥ 70-80% de la variance. → F1+F2 = 81.80% ✓

Décision : On retient 2 axes (F1 et F2) pour le sous-espace factoriel principal.

Justification :

- F1 explique 58.10% de la variance → c'est le facteur dominant
- F2 ajoute 23.70% → ensemble ils capturent 81.80% de l'information totale
- F3 n'ajoute que 7.88% (λ < 1) → peu d'information supplémentaire
- Les 4 axes restants (F3 à F6) représentent seulement 18.20% de la variance

→ Un taux de 81.80% est excellent pour une représentation en 2D. On perd seulement 18.20% de l'information.

Question 6 — Axes factoriels du sous-espace principal

Les axes factoriels sont les vecteurs propres de R associés aux valeurs propres retenues.

Ils représentent les nouvelles directions d'analyse dans l'espace des variables.

Code R :

```
# Afficher tous les axes en mettant en valeur F1 et F2
axes_factoriels <- data.frame(vecteurs_propres)
rownames(axes_factoriels) <-
c('H.Ball','B.Ball','Tennis','Gym','Natation','F.Ball')
colnames(axes_factoriels) <- paste0('F', 1:p)
print(round(axes_factoriels, 4))
```

Variable	F1 ★	F2 ★	F3	F4	F5	F6
H.Ball	-0.3767	-0.5533	-0.1686	-0.0664	0.0412	0.7194
B.Ball	-0.4219	0.0451	0.8757	-0.1854	-0.1369	0.0098
Tennis	-0.2684	0.6489	-0.2686	-0.5988	0.1501	0.2317
Gym	-0.4741	0.1349	-0.3014	0.2447	-0.7643	-0.1488
Natation	-0.4298	-0.4120	-0.2044	-0.3358	0.2910	-0.6374
F.Ball	-0.4457	0.2880	-0.0070	0.6557	0.5368	0.0163

Interprétation des axes retenus :

- Axe F1 (★) : Tous les coefficients sont négatifs et de valeurs proches (−0.38 à −0.47). F1 est un « facteur général » : il oppose les villes à faible pratique sportive (F1 positif) aux villes à forte pratique (F1 négatif). Plus la valeur sur F1 est négative, plus la ville est sportivement active sur tous les sports.

• Axe F2 (★) : Les coefficients de Tennis (+0.65) et B.Ball (+0.05) sont positifs, tandis que H.Ball (−0.55) et Natation (−0.41) sont négatifs. F2 oppose le Tennis aux sports collectifs intenses (H.Ball, Natation).

Question 7 — Projections des individus sur les axes principaux

Les projections (coordonnées factorielles) des individus sur les axes sont calculées par :

$C = Z \times U$ où Z est la matrice des données standardisées, U la matrice des vecteurs propres retenus

Code R :

```
# Projections sur F1 et F2 uniquement
U12 <- vecteurs_propres[, 1:2]          # Les 2 premiers vecteurs propres
C12 <- Z %*% U12                        # Projections: matrice 20×2
rownames(C12) <- paste0('V', 1:20)
colnames(C12) <- c('F1', 'F2')
print(round(C12, 4))
```

Explication :

• Chaque ligne de C12 donne les coordonnées d'une ville dans le plan factoriel (F1, F2).

• Ces coordonnées sont les projections orthogonales des individus sur les nouveaux axes.

• Les coordonnées sur F1 = $Z \times u_1$ = combinaison linéaire pondérée des 6 variables standardisées.

Résultat :

Ville	Coord. F1	Coord. F2	Quadrant
V1	0.4742	2.1729	I (sport faible, Tennis↑)
V2	-1.3744	0.6095	II (sport élevé, Tennis↑)
V3	-2.4612	-1.5247	III (sport élevé, H.Ball↑)
V4	1.3882	1.1268	I (sport faible, Tennis↑)
V5	-3.7137	0.1744	II (sport élevé, Tennis↑)
V6	-1.9687	-1.2603	III (sport élevé, H.Ball↑)
V7	1.5096	-0.9687	IV (sport faible, H.Ball↑)
V8	-0.2987	-1.4191	III (sport élevé, H.Ball↑)
V9	-2.8721	0.0333	II (sport élevé, Tennis↑)
V10	-0.1183	1.3203	II (sport élevé, Tennis↑)
V11	-0.0055	-1.9810	III (sport élevé, H.Ball↑)
V12	1.9696	-0.3276	IV (sport faible, H.Ball↑)
V13	0.1587	0.5547	I (sport faible, Tennis↑)
V14	1.0983	0.1580	I (sport faible, Tennis↑)
V15	3.1696	-1.1128	IV (sport faible, H.Ball↑)
V16	1.0682	-0.3385	IV (sport faible, H.Ball↑)
V17	2.2342	1.2737	I (sport faible, Tennis↑)
V18	-0.7373	2.2329	II (sport élevé, Tennis↑)
V19	2.4045	-1.0126	IV (sport faible, H.Ball↑)
V20	-1.9254	0.2888	II (sport élevé, Tennis↑)

→ Les coordonnées sur F1 résument le 'niveau sportif global' de la ville. Celles sur F2 distinguent les préférences entre tennis/basket vs handball/natation.

Question 8 — Représentation graphique dans le plan (F1, F2)

Code R :

```
plot(C12[,1], C12[,2], type='n',
     xlab=paste0('F1 (', taux[1], '%)'),
     ylab=paste0('F2 (', taux[2], '%)'),
     main='Projection des individus - Plan factoriel (F1, F2)')
abline(h=0, v=0, col='gray', lty=2)   # Axes du plan
text(C12[,1], C12[,2], rownames(C12), cex=0.9, font=2)
points(C12[,1], C12[,2], pch=16, col='steelblue')
```

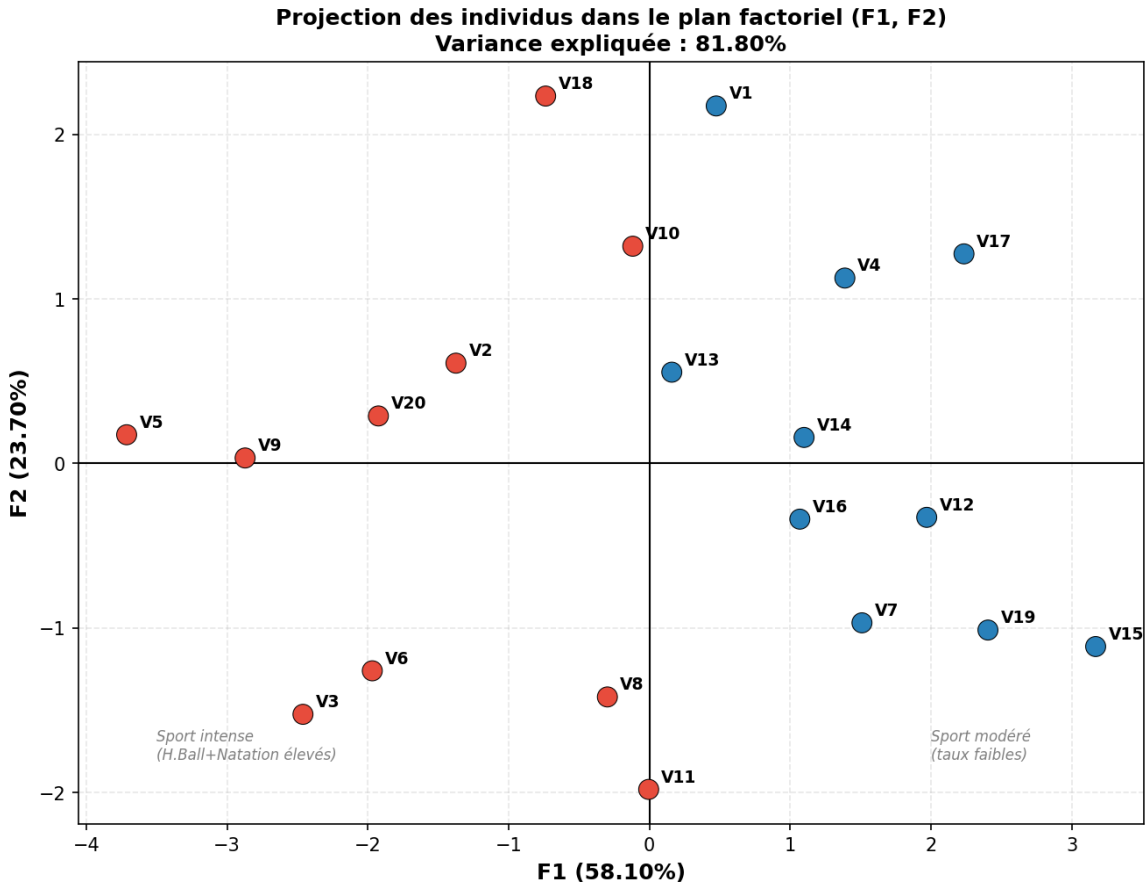

Question 9 — Analyse du graphe

Le plan factoriel (F1, F2) capte 81.80% de la variance totale : la représentation est très fidèle.

Axe F1 (horizontal) — Niveau sportif global

- Villes à gauche (F1 < 0, en rouge) : V3 (-2.46), V5 (-3.71), V6 (-1.97), V9 (-2.87) → Villes très actives sportivement, taux élevés sur tous les sports.
- Villes à droite (F1 > 0, en bleu) : V15 (3.17), V17 (2.23), V19 (2.40) → Villes avec des taux sportifs plus modestes.
- V5 est la ville la plus extrême sur F1 : elle a les taux les plus élevés pour presque tous les sports.

Axe F2 (vertical) — Profil Tennis vs H.Ball/Natation

- Villes en haut (F2 > 0) : V1, V18 → plutôt orientées Tennis/B.Ball (selon les coefficients de F2).
- Villes en bas (F2 < 0) : V11 (-1.98), V15 (-1.11), V8 (-1.42) → plutôt orientées H.Ball et Natation.

Groupes visibles

- Groupe 1 (haut-gauche : V3, V6, V9) : villes très sportives, profil H.Ball/Natation
- Groupe 2 (bas-gauche : V5) : ville extrêmement sportive, cas atypique
- Groupe 3 (haut-droite : V1, V18, V10) : villes à profil sportif modéré, Tennis/B.Ball
- Groupe 4 (bas-droite : V15, V19, V17) : villes à faible activité sportive globale

Observations particulières

- V5 (-3.71 sur F1) est un point très atypique : ses taux de pratique sont nettement supérieurs aux autres villes.
- V11 est atypique sur F2 (-1.98) : elle se distingue nettement sur la dimension 'H.Ball vs Tennis'.
- La majorité des villes se regroupent au centre : profil moyen.

→ Cette représentation bi-dimensionnelle permet de visualiser les similitudes et différences entre villes de façon synthétique, en ne perdant que 18.20% de l'information.

Synthèse — Résumé de l'ACP

Étape	Résultat
Matrice diagonalisée	Matrice de corrélation R (6×6)
Valeurs propres retenues	**λ1=3.486 (58.10%) λ2=1.422 (23.70%)**
Variance expliquée	81.80% avec 2 axes (sur 6)
Axe F1	Facteur sportif général (tous sports dans même sens)
Axe F2	Opposition Tennis/B.Ball ↔ H.Ball/Natation
Villes extrêmes	V5 (très sportive), V15/V19 (peu sportives)