


Le Clustering

HAMID NECIR | COURS FOUILLE DE DONNÉES

Définition:

Le clustering est un processus dont l'objectif est de partitionner (regrouper) un ensemble de données (objets) en un ensemble de groupes appelés clusters

Ces objets sont décrits par des caractéristiques (attributs) qui représentent leur propriétés.



Définition :

, étant donné que le clustering ne se base sur aucune information antérieure c'est un apprentissage non supervisé.

Des fois l'analyste peut fixer le nombre de groupes à obtenir.

Qu'est-ce qu'un cluster?

Un cluster est un ensemble homogène d'objets partageant des caractéristiques communes.

Complexite du clustering

5

NECIR HAMID

Le clustering est un problème hautement complexe, en effet, le nombre de façon de classer N objets en K classes est donné par :

$$P_{n,k} = 1/k! \sum C_k^i (-1)^{k-i} * i^n, \text{ tels que : } i \in [1,k]$$

- Pour une classification optimale de 15 objets en 7 classes, il faut évaluer un peu moins de 5 millions de partitions possibles.
- Pour une classification optimale de 15 objets sans fixer le nombre de classes on aura 1,4 milliards de partitions possibles.

Les application du clustering

6

Le clustering a de nombreuses applications dans:

- ▶ Sciences économiques (notamment études de marché).
- ▶ Marketing: découvrir des groupes distincts de clients, puis utiliser ces connaissances pour développer des programmes de marketing ciblés.
- ▶ Classification des documents
- ▶ Clustering des données d'un site pour découvrir des groupes d'accès similaire
- ▶ La reconnaissance des formes.
- ▶ Analyse des données spatiales:
 - ▶ créer des cartes thématiques dans un SIG en regroupant les espaces d'entités
- ▶ Traitement d'image

Les différentes approches de clustering

7

Suivant les méthodes les clusters peuvent être durs, doux ou floues

1) Clustering dur (Hard clustering) :

- Dans un clustering dur chaque élément appartient à un et un seul cluster, formellement ceci consiste à diviser l'ensemble des données X en K clusters tel que:

$$\bigcup_{i=1}^k C_i = X \text{ et } C_i \cap C_j = \emptyset \text{ avec } i \neq j$$

Exemple:

CLUSTERING DUR

	C1	C2	C3
X1	1	0	0
X2	0	1	0
X3	0	0	1
X4	0	0	1

Les différentes approches de clustering

8

► Clustering doux (soft clustering) :

Il permet à chaque objet d'appartenir à un ou plusieurs clusters. On peut parler de clustering doux partiel si dans le résultat un élément peut appartenir à 1, aucun ou plusieurs clusters.

Exemple:

CLUSTERING DOUX			
	C1	C2	C3
X1	1	1	0
X2	0	1	1
X3	0	1	1
X4	0	0	1

Les différentes approches de clustering

9

Clustering floue (fuzzy clustering) :

Il permet à chaque élément d'appartenir à chacun des clusters selon un degré d'appartenance.

Il est toujours possible de revenir à un clustering dur en choisissant pour chaque objet, le cluster dont l'appartenance est maximale.

Exemple:

CLUSTERING FLOUE			
	C1	C2	C3
X1	0.9	0.1	0
X2	0	0.8	0.2
X3	0	0.3	0.7
X4	0	0	1

Mesure de similarité

10

Une bonne méthode de clustering permet de maximiser la ressemblance entre les données à l'intérieur de chaque cluster et de minimiser la ressemblance entre les données appartenant à des clusters différents.

Le clustering dépend fortement de la mesure de similarité, en effet, la similarité permet d'évaluer deux éléments pour les regrouper ou les séparer, cette notion de similarité est une première étape pour définir un algorithme de clustering, elle sera suivie par une étape décrivant la stratégie de construction de cluster.

Le calcul de distance

11

NECIR HAMID

- La notion de similarité repose sur le calcul de distance entre deux données, chaque donnée est composée d'un ensemble d'attribut numérique et/ou catégorique.

a- Propriétés de la distance :

Soit x_i et x_j deux données différentes dont on veut calculer la distance.

- 1) $d(x_i, x_j) = d(x_j, x_i)$
- 2) $d(x_i, x_j) \geq 0$
- 3) $d(x_i, x_j) = 0$ ssi $x_i = x_j$

1) Calcul de distance pour attributs numérique

12

► 1.1- Distance euclidienne :

► Pour deux objet x_i et x_j , n dimensionné

► $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{in})$

► $x_j = (x_{j1}, x_{j2}, x_{j3}, \dots, x_{jn})$

$$D_n(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$$

Exemple

13

NECIR HAMID

- Pour $X_1(0; 2); X_2(0; 0); X_3(1,5; 0)$; calculer les distance séparant X_1 , X_2 et X_3

$$D(x_1, x_2) = \sqrt{(0 - 0)^2 + (2 - 0)^2} = 2$$

$$D(x_1, x_3) = \sqrt{(0 - 1,5)^2 + (2 - 0)^2} = 2,5$$

$$D(x_2, x_3) = \sqrt{(0 - 1,5)^2 + (0 - 0)^2} = 1,5$$

1) Calcul de distance pour attributs numérique

14

NECIR HAMID

- ▶ 1.2- Distance City Block (Manhattan):
- ▶ Pour deux objet x_i et x_j , n dimensionné
- ▶ $x_i = (x_{i1}, x_{i2}, x_{i3}, \dots, x_{in})$
- ▶ $x_j = (x_{j1}, x_{j2}, x_{j3}, \dots, x_{jn})$

$$D_n(x_i, x_j) = \sum_{k=1}^n |x_{ik} - x_{jk}|$$

Exemple

15

- Pour $X_1(0; 2); X_2(0; 0); X_3(1,5; 0)$; calculer les distance séparant X_1 , X_2 et X_3

$$D(x_1, x_2) = |0 - 0| + |2 - 0| = 2$$

$$D(x_1, x_3) = |0 - 1,5| + |2 - 0| = 3,5$$

$$D(x_2, x_3) = |0 - 1,5| + |0 - 0| = 1,5$$

1.3- Distance de Hamming:

16

NECIR HAMID

Pour deux séquences binaires de même taille est égale en nombre de bits de rang identique par lesquelles elles diffèrent.

Exemple:

$X1 = 100111$

$X2 = 010100$

$$D(X1, X2) = 4$$

1.3- Distance pour Attribut catégorielle :

Le problème qui se pose lors du calcul de la distance entre attribut catégorielle c'est qu'on ne dispose pas d'une mesure de différence, la seule mesure qui existe c'est l'égalité ou l'inégalité.

$$\begin{cases} D_c(x_i, x_j) = \frac{1}{n_c} \sum_{k=1}^{n_c} f(x_{ik}, x_{jk}) \\ f(x_{ik}, x_{jk}) = 1 \quad \text{si} \quad x_{ik} \neq x_{jk}, \quad 0 \quad \text{sinon} \end{cases}$$

Il faut en fin la normaliser avec les attributs numériques et le nombre d'attributs catégoriels.
La distance entre deux données x_i et x_j , composées d'attributs numériques et catégoriels, est donc :

1.3- Distance pour Attribut catégorielle :

Il faut en fin la normaliser avec les attributs numériques et le nombre d'attributs catégoriels.

La distance entre deux données x_i et x_j , composées d'attributs numériques et catégoriels, est donc :

$$D(x_i, x_j) = D_n(x_i, x_j) + D_c(x_i, x_j)$$

2) Clustering hiérarchique

19

Dans ce type de clustering le nombre de clusters ne peut être connu à l'avance. Le système prend en entrée l'ensemble de données et fournit en sortie une arborescence de clusters.

Il existe deux classe de ce type d'algorithmes :

Clustering hiérarchique

20

NECIR HAMID

Il existe deux classe de ce type d'algorithmes :

1. **les algorithmes divisibles** qui commencent à partir d'un ensemble de données et le subdivisent en sous ensembles puis subdivisent chaque sous ensemble en d'autres plus petits, et ainsi de suite, pour générer en fin une séquence de clusters ordonnée du plus général au plus fin.
2. **Les algorithmes agglomératifs** qui considèrent chaque enregistrement comme étant un cluster indépendant puis rassemblent les plus proches en des clusters plus importants, et ainsi de suite jusqu'à atteindre un seul cluster contenant toutes les données.

Un algorithme agglomératif suit généralement les étapes suivantes :

Algorithme agglomératif

21

NECIR HAMID

Un algorithme agglomératif suit généralement les étapes suivantes :

- 1: Placer chaque objet dans son propre cluster ;
- 2: Tant que il y a des objets a agglomérer
 - 2.1: Calculer une liste des distances entre les clusters et la trier dans l'ordre croissant ;
 - 2.2: agglomérer les objets ayant la distance minimale.
 - 2.3: calculer le centre du nouveau cluster

Fait

Exercice

22

NECIR HAMID

Soient les données suivantes : $X1(0; 2); X2(0; 0); X3(1; 5; 0); X4(5; 0); X5(5; 2)$.

Appliquez l'algorithme hiérarchique agglomératif.

On utilise la distance city Block pour mesurer la distance entre les données :

$X1(0; 2); X2(0; 0); X3(1; 5; 0); X4(5; 0); X5(5; 2).$

On calcule les distances entre les données.

$$D(X1, X2) = 2$$

$$D(X1, X3) = 3.5$$

$$D(X1, X4) = 7$$

$$D(X1, X5) = 5$$

$$D(X2, X3) = 1.5 \quad \leftarrow \text{Distance Minimale Distance Minimale}$$

$$D(X2, X4) = 5$$

$$D(X2, X5) = 7$$

$$D(X3, X4) = 3.5$$

$$D(X3, X5) = 5.5$$

$$D(X4, X5) = 2$$

Regrouper $X2, X3$

$M1 = (0.75; 0)$ centre des $X2, X3$

$X1(0; 2); M1(0.75; 0); X4(5; 0); X5(5; 2).$

On calcule les distances entre les données.

$$D(X1, X4) = 7$$

$$D(X1, X5) = 5$$

$$D(X1, M1) = 2.75$$

$$D(X4, M1) = 4.25$$

$$D(X4, X5) = 2 \quad \leftarrow \text{Distance Minimale}$$

$$D(X5, M1) = 6.25$$

Regrouper $X4, X5$

$$M2 = (5; 1)$$

$X1(0; 2); M1(0.75; 0); M2(5; 1)$

On calcule les distances entre les données.

$D(X1, M1) = 2.75$ ← Distance Minimale

$D(X1, M2) = 6$

$D(M1, M2) = 5.25$

Regrouper $X1, M1$

$M3 = (0 + 0.75)/2; (2 + 0)/2 = (0.38; 1)$

$M2(5; 1); M3(0.38; 1)$

On calcule les distances entre les données.

$D(M2, M3) = 4.62$


Regrouper $M2, M3$

$M4 = (5 + 0.38)/2; (1 + 1)/2 = (2.69; 1)$

Dendrogramme

26

NECIR HAMID



Clustering hiérarchique partitionnel

27

On commence à partir d'un ensemble de données et on le subdivise en sous ensembles puis on subdivise chaque sous ensemble en d'autres plus petits, et ainsi de suite, pour générer en fin une séquence de clusters ordonnée du plus général au plus fin.

Algorithme kmeans

28

NECIR HAMID

- Le plus simple et le plus utilisé des algorithmes partitionnel.
- K-means démarre d'un nombre d'objets repartis arbitrairement sur les k clusters.
- K étant donné par l'utilisateur.
- A chaque itération, on calcule les centres de ces clusters puis on effectue une nouvelle affectation des objets aux plus proches centres.
- Il s'arrête dès qu'un critère d'arrêt est satisfait, généralement on s'arrête si aucun objet ne change de cluster.

Algorithme kmeans

29

NECIR HAMID

L'algorithme kmeans suit généralement les étapes suivantes :

- 1: Sélectionner K clusters initiaux contenant des objets choisis arbitrairement,
- 2: calculer les centres des clusters ;
- 3: Calculer une liste des distances interclusters et la trier dans l'ordre croissant ;
- 4: Générer une nouvelle partition en affectant chaque objets au cluster du centre le plus proche ;
- 5: Calculer les nouveaux centres des clusters ;
- 6: Répéter 3 et 5 jusqu'à ce que les objets se stabilisent dans leurs clusters ;

Intérêt de *K-means*

30

NECIR HAMID

- ▶ Simplicité conceptuelle et de réalisation
- ▶ complexité algorithmique relativement faible : $(O(t \cdot k \cdot N))$,
Avec t : le nombre d'itérations,
 k : le nombre de groupes (ou de centres)
 N : le nombre de données.
- ▶ le nombre d'itérations nécessaire pour obtenir la convergence peut être fortement réduit avec une bonne initialisation,
- ▶ Présence d'un unique paramètre, qui est la valeur souhaitée pour le nombre de clusters(k).

Exemple

31

- ▶ $X1(0; 3); X2(0; 0); X3(2; 0); X4(6; 0); X5(5; 2),$
- ▶ On commence par choisir une affectation arbitraire des données
- ▶ $C1 = (X1; X2; X4)$ et $C2 = (X3; X5).$

On calcule les deux centres :

$$M1 = (2; 1)$$

$$M2 = (3.5; 1)$$

On calcule la distance entre chaque donnée X_i et les centres $M1$ et $M2$, puis on affecte chaque données au cluster le plus proche.

$$D(X1, M1) = 4$$

$$D(X1, M2) = 5.5$$

$$D(X2, M1) = 3$$

$$D(X2, M2) = 4.5$$

$$D(X3, M1) = 1$$

$$D(X3, M2) = 2.5$$

Exemple

32

NECIR HAMID

- ▶ $D(X4, M1) = 5$
- ▶ $D(X4, M2) = 5.5$
- ▶ $D(X5, M1) = 4$
- ▶ $D(X5, M2) = 2.5$
- ▶ La nouvelle affectation est $C1 = (X1; X2; X3; X4)$, $C2 = (X5)$

On calcule les deux centres :

$$M1 = (2; 0.75)$$

$$M2 = (5; 2)$$

Exemple

33

NECIR HAMID

- ▶ $D(X1, M1) = 4.25$
- ▶ $D(X1, M2) = 6$
- ▶ $D(X2, M1) = 2.75$
- ▶ $D(X2, M2) = 7$
- ▶ $D(X3, M1) = 0.75$
- ▶ $D(X3, M2) = 5$
- ▶ $D(X4, M1) = 4.75$
- ▶ $D(X4, M2) = 3$
- ▶ $D(X5, M1) = 4.25$
- ▶ $D(X5, M2) = 0$
- ▶ La nouvelle affectation est $C1 = (X1; X2; X3)$, $C2 = (X4; X5)$.

On calcule les deux centres :

$$M1 = (0.67; 1)$$

$$M2 = (5.5; 1)$$

Exemple

34

NECIR HAMID

- ▶ $D(X1,M1)=2.67$
- ▶ $D(X1,M2)=7.5$
- ▶ $D(X2,M1)= 1.67$
- ▶ $D(X2,M2)=6.5$
- ▶ $D(X3,M1)=2.33$
- ▶ $D(X3,M2)=4.5$
- ▶ $D(X4,M1)=6.33$
- ▶ $D(X4,M2)=1.5$
- ▶ $D(X5,M1)=5.33$
- ▶ $D(X5,M2)=1.5$
- ▶ La nouvelle affectation est $C1 = (X1;X2;X3)$, $C2 = (X4;X5)$.

Stabilité, l'algorithme s'arrête