

Les Règles d'association

HAMID NECIR | COURS FOUILLE DE DONNÉES

Définition

- ▶ La fouille de données (data mining) vise à découvrir, dans les grandes quantités de données, les informations précieuses qui peuvent aider à comprendre les données ou à prédire le comportement des données futures.
- ▶ Le datamining utilise depuis son apparition plusieurs outils de statistiques et d'intelligence artificielle pour atteindre ses objectifs.

Introduction

- ▶ Rechercher des régularités dans les données
- ▶ Trouver des schémas fréquents, des associations, des corrélations parmi des ensembles d'articles dans des bases de données de transactions
- ▶ Comprendre les habitudes d'achat des clients en trouvant des associations et corrélations entre les différents achats que les clients placent dans leur "panier"

Applications :

- ▶ Rayonnage, mailing,...
- ▶ Analyse des données du panier,
- ▶ marketing croisé,
- ▶ conception de catalogue,
- ▶ analyse de journal Web, détection de fraude

Etapes de l'approche

Approche en deux étapes:

1. Extraction des itemsets fréquents (Motifs)

- Extraction de tous les ensembles d'éléments qui apparaissent fréquemment

2. Génération de règles

- Générez des règles de confiance élevées à partir de chaque ensemble d'éléments fréquents. déjà extrait

Etape 1: génération des itemsets fréquents

Etape 1: génération des itemsets fréquents

Concepts de base

Soit $I = \{i_1, i_2, \dots, i_n\}$ un ensemble d'éléments appelés items.

- ▶ Une base de données D consiste en un ensemble de transactions T_i tel que: $T_i \subseteq I$
- ▶ On dit que T contient X si $X \subseteq T$
- ▶ **Item (motif)** : Correspond à une valeur d'un attribut dans la base de transactions,
- ▶ **Itemset** : un itemset X est un ensemble d'items $X \subseteq I$
- ▶ **K-itemset** : est un itemset de longueur k (formé de k items).

- **Exemple :**

Pour les items $\{A, B, C\}$ on a:

les 1-itemset: A B C

les 2-itemset: AB AC BC

les 3-itemsets: ABC

Problèmes

Générer tous les itemsets est très complexe.


N items



$2^N - 1$ itemsets possible

- Comment garder en mémoire un nombre important d'itemsets ?
 - 100 items $\Rightarrow 2^{100} - 1$ itemsets possibles !!!!
- Comment calculer la fréquence d'apparition d'un nombre important d'itemsets dans une grande base de données (100 million de transactions) ?

Exemple : Les itemsets possibles pour 3 items {A, B, C}.



Mesures utilisées

- **Support** : facteur de fiabilité de la règle .

Le support d'un itemset X noté $\text{Sup}(X)$ est la proportion de transaction de D contenant X.

$$\text{Sup}(X) = \text{Freq}(X) / |D|$$

où $\text{Freq}(X)$: nombre des transactions dans D qui contiennent l'itemset X. $\text{Sup}(X) \in [0,1]$

- **Itemset fréquent** : On appelle X un itemset fréquent si:

$$\text{Sup}(X) \geq \text{MinSup}$$

où MinSup est le seuil minimal transmit par l'utilisateur. $\text{MinSup} \in [0,1]$

Propriétés de l'algorithme Apriori

1) Propriété de monotonie: *tous les sous ensembles d'un itemset fréquent sont aussi fréquents.*

Exemple:

si ABCD est un d'itemset fréquents, alors, les sous ensembles :ABC,ABD, BCD, AB,AC,BC,BD,CD,A,B,C,D les sont aussi.

2) Propriété d'anti monotonie:

tous les sur ensembles d'un itemset infrequent sont aussi infrequent.

Exemple:

si AB est un itemset infrequent, alors, les sur ensembles :ABC,ABD les sont aussi.

Algorithme Apriori

Entrée: K : Contexte d'Extraction, Minsup

Sortie: Ensemble des itemsets fréquents

1: Initialiser l'ensemble de candidats de taille 1

2: **tant que** ensemble de candidats est non vide **faire**

- 1) Calculer le support des candidats
- 2) Élaguer l'ensemble de candidats par rapport à minsup

Étape d'élagage (ou de test)

- 1) Construire l'ensemble des candidats pour l'itération suivante

Étape de construction

5: **fin tant que**

6: **retourner** Ensemble des itemsets fermés fréquents

Exemple

12

Soit D la base de transactions contenant un ensemble de transaction décrivant des achats de produits dans l'ensemble {A, B, C, D, E}

	A	B	C	D	E
T1	1	0	1	0	1
T2	1	1	1	0	0
T3	1	0	0	1	1
T4	0	1	1	0	1
T5	0	1	1	0	0

Exemple

13

Les étapes d'extraction des itemsets fréquents par l'algorithme Apriori sont:
MinSup=2/5

1-itemset	Sup
A	3/5
B	3/5
C	4/5
D	1/5
E	3/5

 **infréquent**

2-itemset	Sup
AB	1/5
AC	2/5
AE	2/5
BC	3/5
BE	1/5
CE	2/5

 **infréquent**

 **infréquent**

3-itemset	Sup
ACE	1/5

 **infréquent**

Etape 2: génération des règles d'association

Règle d'association

15

Règle d'association : Indication de précision de la règle. Implication de la forme:

$$A \rightarrow B$$

où $A, B \subseteq I$, $B \subseteq I$ et $A \cap B = \emptyset$

A est dit Antécédant et B est dit Conséquent.

Une règle d'association exprime le fait que les items de A tendent à apparaître avec ceux de B.

Mesure de qualité d'une règle d'association

Confiance: La confiance d'une règle d'association $A \rightarrow B$, représente la proportion (Pouvant être exprimé en pourcentage) de transactions couvrant A qui couvrent aussi B.

$$\text{Confiance}(A \rightarrow B) = \text{Sup}(AB) / \text{Sup}(A)$$

Règle solide : Une règle d'association $A \rightarrow B$ est solide si sa confiance dépasse un seuil donné, fixé a priori, appelé **MinConf**.

Règle forte : Une règle d'association $A \rightarrow B$ est forte si sa confiance est égale a 1 (100%).

Mesure de qualité d'une règle d'association

Lift: Mesure le caractère significatif de l'association.

$$\text{Lift}(A \rightarrow B) = \text{Sup}(AB) / (\text{Sup}(A) \cdot \text{Sup}(B))$$

- Un lift supérieur à 1 : Indique une corrélation positive
- Un lift de 1 indique une corrélation nulle
- Un lift inférieur à 1 : Indique une corrélation négative

Exemple

18

Les étapes d'extraction des règles d'association. On considère $\text{MinConf}=3/5=0,67$

itemset	règles d'association	Lift	Confiance
AC	$A \rightarrow C$	1,40	$\text{Conf}(A \rightarrow C)=0,67$
	$C \rightarrow A$	1,40	$\text{Conf}(C \rightarrow A)=0,5$
AE	$A \rightarrow E$	1,11	$\text{Conf}(A \rightarrow E)=0,67$
	$E \rightarrow A$	1,11	$\text{Conf}(E \rightarrow A)=0,67$
BC	$B \rightarrow C$	1,25	$\text{Conf}(B \rightarrow C)=1$
	$C \rightarrow B$	1,25	$\text{Conf}(C \rightarrow B)=0,75$
CE	$C \rightarrow E$	0,83	$\text{Conf}(C \rightarrow E)=0,5$
	$E \rightarrow C$	0,83	$\text{Conf}(E \rightarrow C)=0,67$

← Règle forte

L'algorithme CLOSE

19

- Proposé en 1998 par Pasquier et al.
- Algorithme itératif par niveau pour l'extraction des itemsets fermés fréquents.
- Durant chaque itération k de l'algorithme, un ensemble de k -générateurs candidats est considéré. Chaque élément de cet ensemble est constitué de trois éléments : le k -générateur candidat, sa fermeture, et leur support.
- À la fin de l'itération k , l'algorithme stocke un ensemble contenant les k -générateurs fréquents, leurs fermetures, qui sont des itemsets fermés fréquents, et leurs supports.

Algorithme CLOSE

20

Entrée: K : Contexte d'Extraction, minsup

Sortie: Ensemble des itemsets fermés fréquents

1: Initialiser l'ensemble de candidats de taille 1

2: tant que ensemble de candidats est non vide **faire**

- 1) Calculer le support des candidats
- 2) Élaguer l'ensemble de candidats par rapport à minsup
- 3) calculer les fermetures des candidats retenus

Étape d'élagage (ou de test)

- 1) Construire l'ensemble des candidats pour l'itération suivante
- 2) Élaguer cet ensemble en utilisant les propriétés des itemsets fermés.

Étape de construction

5: fin tant que

6: retourner Ensemble des itemsets fermés fréquents

Exemple

Soit D la base de transactions contenant un ensemble de transaction décrivant des achats de produits dans l'ensemble {A, B, C, D, E} . $\text{MinSup}=2/5$

A	B	C	D	E
1	1	1	1	1
1	1	0	0	0
0	0	1	0	1
1	1	0	1	1
1	0	1	1	0

Exemple

22

Les étapes d'extraction des itemsets fréquents par l'algorithme CLOSE sont:

1-Gen	Sup	Ferm
A	4/5	A
B	3/5	AB
C	3/5	C
D	3/5	AD
E	3/5	E



2-itemset	Sup	Ferm
AC	2/5	ACD
AE	2/5	ABDE
BC	1/5	ABCDE
BD	2/5	ABDE
BE	2/5	ABDE
CD	2/5	ACD
CE	2/5	CE
DE	2/5	ABDE



3-itemset	Sup	Ferm
ACE	1/5	ABCDE
CDE	1/5	ABCDE

Exemple

23

règles d'association	Confiance	Lift
$B \rightarrow A$	Confiance=1	1,25
$D \rightarrow A$	Confiance=1	1,67
$AC \rightarrow D$	Confiance=1	4,17
$AE \rightarrow BD$	Confiance=1	6,25
$BD \rightarrow AE$	Confiance=1	6,25
$BE \rightarrow AD$	Confiance=1	4,17
$CD \rightarrow A$	Confiance=1	3,13
$DE \rightarrow AB$	Confiance=1	4,17

Les Règles d'association (Partie 2)

HAMID NECIR | COURS FOUILLE DE DONNÉES

- ▶ La recherche des itemset fréquent est une solution satisfaisante pour réduire le nombre des itemsets extraits

- ▶ **Problème dans le cas d'un contexte dense**

Les performances se dégradent considérablement lorsqu'il s'agit de très grande base de données fortement corrélées (la matrice comporte peu de zéro) où les itemsets fréquent peuvent être trop long (de taille) comme le cas des bases de données boursière ou biologique.

- ▶ **Solution**

L'approche des itemsets maximaux a pour but de ne considérer que les item-set les plus long parmi les itemsets fréquent.

Contexte et Tid de transaction

26

NECIR HAMID

- ▶ Une base de données de transactions est un ensemble de transactions.
- ▶ Chaque transaction contient un ensemble d'items.

TRANSACTIONS	ITEMS
T1	ABCD
T2	AD
T3	AE
T4	CE

Definition d'un itemset maximal

27

- ▶ Un itemset fréquents est dit maximaux si tous ces sur-ensembles sont infrequentés et tous ses sous itemsets sont fréquents.

Extraction des itemsets maximaux

28

NECIR HAMID

L'extraction des itemsets fréquents maximaux est réalisée par une exploration itérative du treillis des itemsets fréquents, en « avançant » d'un niveau du bas vers le haut et de un ou plusieurs niveaux du haut vers le bas lors de chaque itération.

- ▶ À partir des itemsets fréquents maximaux, tous les itemsets fréquents sont dérivés et leurs supports sont déterminés en réalisant un balayage du contexte.

Plusieurs algorithmes ont été proposés pour l'extraction des itemset maximaux, l'objectif étant d'éviter le parcours exponentiel de l'espace de recherche en trouvant au plus vite les plus grands itemsets fréquents, on peut citer les algorithmes Max-Miner & Mafia.

Minsup = 2/6

Req \ Att	A3	A6	A7	A10
T1	1	0	1	1
T2	1	0	1	1
T3	1	0	0	0
T4	1	1	0	0
T5	1	1	0	0
T6	0	0	1	1
Sup	4/6	2/6	3/6	3/6



{<A6>, <A7>}

