

Règle d'association

- Data mining utiliser pour analyser de très grande quantité de donnée, afin de découvrir des information utiles, cachées ou importantes

Cherche

- ↳ répétition
- ↳ association
- ↳ comportement fréquents

Objetif → Transformer
les donnée en information
utiles

Association:

Deux produits souvent achetés
ensemble ex: café + sucre

Corrélation:

Deux choses évoluent ensemble
↳ température ↑
vente de glace ↑

Analyse du panier:

étudier ce que les clients
achète

On Approche deux étapes:

- ↳ Extraction des items et fréquents
- ↳ Génération des règles

1) Itemset: Collection (ensemble) d'article

2) Transaction: Achat, Vente, ou tout autre événement

3) Règle d'association: "Si — alors"

A: Antécédent
B: Conséquent

$A \rightarrow B$ { Si: un client achète A, }
 { alors il achète B }

Support Le support d'un produit est la proportion de transaction D contenant X

$$\text{Sup}(x) = \text{Freq}(x) / |D|$$

- $\text{Freq}(x)$: Nbre de transaction contenant (x)

- $|D|$: Nombre total de transaction

Itemset fréquent On appelle X un itemset fréquent, si

$$\text{Sup}(x) \geq \text{minsup}$$

↳ seuil minimal fourni par l'utilisateur $\in [0, 1]$

Propriété monotonicité :

- Si un itemset est fréquents, alors : tout sous ensembles sont aussi fréquents

Ex: Si ABCD est fréquents alors

soient fréquents

- ABC
- ABD
- ACD
- BCD
- AB
- AC
- AD
- BC
- BD
- CD

Propriété anti-monotonie

itemset infrequent $\rightarrow$

tous ses sous ensembles infrequent

Ex: AB infrequent $\rightarrow$ ABC

ABD

ABCD

aussi infrequent

HADA HOUWA

l'élagage

Algo Apriori

Extraction des Itemset fréquents

Entrée :

- Contexte d'extraction K : dataset
- Minsup

Sortie

ensemble des itemsets
fréquents

Étapes

- ① Initialisation : Créer les candidats de taille 1 (C_1)
 - ② Boucle principale : Calculer support de chaque candidat
 - ③ Élagage : Supprimer les candidats dont $\text{sup}(x) < \text{MinSup}$
 - ④ Construction des n^{e} candidats : C_{k+1}
- Boucle jusqu'à il n'y a plus de candidats

Ex

Minsup = 2/5

	A	B	C	D	E
T_1	1	0	1	0	1
T_2	1	1	1	0	0
T_3	1	0	0	1	1
T_4	0	1	1	0	1
T_5	0	1	1	0	0

Item 1

A	3/5
B	3/5
C	4/5
D	1/5 $\times$
E	3/5

Item 2

AB	1/5 $\times$
AC	2/5
AE	2/5
BC	3/5 $\times$
BE	0/5
CE	2/5

On a : AC et AE
fréquents

et il a un

Préfixe Commun

AC + AE $\rightarrow$ ACE

Item 3

ACE	1/5 $\times$
-----	--------------

On compare les items de la taille $k-1$ (1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66, 67, 68, 69, 70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82, 83, 84, 85, 86, 87, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99, 100)

Règle d'association:

$$A \rightarrow B$$

Proportions en %

$A \subset I$ antécédant

$B \subset I$ conséquent

$A \cap B = \emptyset$: aucun élément commun entre A et B

Les items de A tendent à apparaître avec ceux de B

Mesure de Qualité:

Confiance (Confidence)

La Confiance d'une Règle $A \rightarrow B$ Représente la Proportion (Pourcentage) de T couvrant A qui couvrent aussi B

$$\text{Confiance}(A \rightarrow B) = \text{Sup}(AB) / \text{Sup}(A)$$

- Règle Solide : Confiance($A \rightarrow B$) = Min Conf on départ

- Règle forte : Confiance($A \rightarrow B$) = 1 (100%) Règle tjr Vrai

Lift

• Si deux éléments sont vraiment liés ou juste apparaissent ensemble par hasard

$$\frac{\text{Conf}(A \rightarrow B)}{\text{Sup}(B)} = \text{Lift}(A \rightarrow B) = \frac{\text{Sup}(A \cap B)}{\text{Sup}(A) \cdot \text{Sup}(B)}$$

hbr de T où A et B apparaissent ensemble

$\text{Lift} > 1 \rightarrow$ relation positif : A et B apparaissent souvent ensemble

$\text{Lift} = 1 \rightarrow$ aucune relation

$\text{Lift} < 1 \rightarrow$ relation négatif : A et B évitent d'apparaître ensemble
Produit qui ne jamais apparaître ensemble.

Lift > 1 : Corrélation positive

Lift = 1 : // nulle

Lift < 1 : corrélation négative

Ex : Super

$$\text{Minconf} = \frac{3}{5} = 0.67$$

	Règle associée	Sup (A ∩ B)	Sup(A)	Sup(B)	Confiance	Lift	Solide?
A C	A → C	2/5	3/5	4/5	0.67	0.83	✓
	C → A	2/5	3/5	3/5	0.5	0.83	✗
A E	A → E	2/5	3/5	3/5	0.67	1.11	✓
	E → A	2/5	3/5	3/5	0.67	1.11	✓
B C	B → C	3/5	3/5	4/5	1	1.25	forte
	C → B	3/5	4/5	3/5	0.75	1.25	✓
B E	B → E	2/5	4/5	3/5	0.5	0.83	✗
	E → B	2/5	3/5	4/5	0.67	0.83	✓

Règle forte B → C avec confiance = 1 signifie que 100% des clients qui achètent B achètent aussi C
c'est la règle la plus fiable

Algorithme Close: Calcul des itemsets fréquents

c-à-d aucun sous-ensemble n'a même support

• Quand on passe de $k=1$ vers $k=2$ puis vers $k=3$

On ne garde pas les itemsets inutiles ou déjà représentés par une fermeture

Ex:

" Extraction des Itemset fréquent

	A	B	C	D	E
T ₁	1	1	1	1	1
T ₂	1	1	0	0	0
T ₃	0	0	1	0	1
T ₄	1	1	0	1	1
T ₅	1	0	1	1	0

Gen1	sup	fer
A	4/5	A
B	3/5	AB
C	3/5	C
D	3/5	AD
E	3/5	E

x →

2-itemset	sup	fer
AC	2/5	ACD
AB	2/5	ABDE
BC	1/5	ABCDDE
BD	2/5	ABDE
BE	2/5	ABDE
CD	2/5	ACD
CE	2/5	CE
DE	2/5	ABDE

Si on trouve la fermeture dans on case T₃ la

Par exemple dans A et B

je trouve fermeture AB

Je prend pas dans item prochains, si on prend

Item2	Sup	fermeture
AC	2/5	ACD
AE	2/5	ABDE
BC	1/5 _x	ABCDE
BD	2/5	ABDE
BE	2/5	ABDE
CD	2/5	ACD
CE	2/5	CE
DE	2/5	ABDE

- dans Item 1
 je prend par AB
 par la suite de AB
 aussi par AD
 et par AE
 et par D

↓

Item3	Sup	fermeture ABCDE
ACE	1/5	ABCDE
CDE	1/5	ABCDE

1^{re} Règle d'association

	cnf	cidt
B → A	1, 2, 5	1, 2, 5
D → A	1, 2, 5	1, 6, 7
AC → D	1	1, 6, 7
AE → BD	1	2, 5
BD → AE	1	2, 5
BE → AD	1	1, 6, 7
CD → A	1	1, 2, 5
DE → AB	1	1, 6, 7

A → B

$$cnfs = \frac{Sub(A \cap B)}{Sup(A)}$$

Clustering

• Cluster: Un groupe d'objets similaires entre eux

Clustering: méthode qui crée automatiquement des groupes similaires

- le clustering est problématique car il existe très grand nombre de façons possible de regrouper les objets

K est fixé

↓

l'algo cherche

seulement la

Partition contenant

exactement K groupes

K n'est pas fixé

↓

doit tester ~~le~~ le nombre possible de clusters:

$K = 1, 2, 3, \dots, N$

Nombre d'objets

différentes approches de clustering

Clustering dur (Hard)

chaque objet $\in$ à un seul cluster uniquement

Clustering doux (Soft)

Un objet peut appartenir à plusieurs clusters

Clustering flou (fuzzy)

chaque objet $\in$ à tous les clusters avec un degré

ex: 90% C_1 10% C_2 0% C_3

- les objets Simblables doivent être dans le même Cluster
- les objets différents doivent être dans des clusters différents

Obj

↳ Maximiser $\hookrightarrow$ minimiser Similarity
 ↓
 objets dans même cluster doivent être semblables
 b c q
 en groupes doivent être différents les uns des autres

Calcul de distance:

- Petit distance $\rightarrow$ Objets similaires
- Grande distance $\rightarrow$ différents
- Propriétés:
 - Symétrie $d(x_i, x_j) = d(x_j, x_i)$
 - Positivité $d \geq 0$
 - Identité $d(x_i, x_j) = d(j, j)$ même objet

Type

1. numérique:

* euclydienne:

$$D(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$$

$$\begin{aligned} D(x_1, x_2) \quad & x_1 = (0, 2) \\ & x_2 = (0, 0) \\ D &= \sqrt{(0-0)^2 + (2-0)^2} \\ D &= \sqrt{4} = 2 \end{aligned}$$

* Manhattan: City block

- rue en grille

$$d(x_i, x_j) = \sum_{k=1}^n |x_{ik} - x_{jk}|$$

* Hamming: pour les données binaires

nbr de position où deux chaînes sont différentes

(2)

2. categorielle: Valeur non numérique

alors on compare: égal / différent

distance catégorielle:

↳ Si les valeurs identiques $\rightarrow$ distance = 0

↳ Si elles sont différentes $\rightarrow$ distance = 1

$$D_c(x_i, x_j) = \sum_{k=1}^n f(x_i, x_j)$$

distance total

Somme des deux distances: numérique + catégorielle

Evaluation qualité de clustering

↳ distance inter-classe: entre deux C

Plus c'est grand = meilleurs clusters

↳ distance intra-classe: intra-cluster (à l'intérieur)

les objets doivent être proches = petite distance



Evaluation distance inter-classe

- Single link: On prend la plus petite distance
- Complete link: On prend la plus grande distance
- Average link: On fait la moyenne de toutes les distances
- Centroid link: on calcule un seul point = centre du groupe
- Fuzzy Centroid link: le centre de deux clusters fusionnés.
- = Somme des diff coordonnées / nbr d'éléments

(3)

Clustering hiérarchique

C'est une méthode de clustering qui construit une structure en forme d'arbre

↳ On ne donne pas le nombre de clusters à l'avance

2 type

Agglomératif (Ascendant) = CAH

↳ On part de petit groupe et on les fusionne

Divisif ("algorithm-divisible" (descendant))

On commence avec tout le monde ensemble

CAH

- Chaque objet devient cluster
- On calcule la distance entre tt les clusters
- on les trie
- Fusion : On prend la distance la plus petite et on fusionne les 2 clusters

- Calculer le centre de n clusters $C = \frac{1}{n} \sum_{i=1}^n x_i$

Dendrogramme : arbre qui montre comment les clusters se forment dans clustering.

Algorithme Kmeans

- Algorithme de clustering partitionnel

Que fait k-means? - on choisit k groupes

Cluster
 $O(t.k.N)$
 Iteration

des données

- on place des centres au hasard
- on affecte chaque point au centre le plus Proche
- on recalcule les centres
- on répète jusqu'à stabilité

ما ما 2=3

Ex:

$x_1(0, 3); x_2(0, 0); x_3(2, 0); x_4(6, 0); x_5(1, 2)$

$k=2$

$M_1(2, 1) \quad M_2(3, 5; 1)$

On commence par choisir une affectation arbitraire des données

$C_1(x_1; x_2; x_4) \quad C_2(x_3; x_5)$

- On calcule les deux centres: $M_1(2, 1) / M_2(3, 5; 1)$

- On calcule la distance entre chaque donnée x_i et les Centres M_1 et M_2 , puis on affecte chaque donnée au cluster le plus proche

$D(x_1, M_1) = 4$ | $D(x_1, M_2) = 1,4$ nouvelle affectation

$D(x_2, M_1) = 3$ | $D(x_2, M_2) = 4,1$ $C_1(x_1, x_2; x_3)$

$D(x_3, M_1) = 1$ | $D(x_3, M_2) = 2,1$ $C_2(x_4, x_5)$

$D(x_4, M_1) = 5$ | $D(x_4, M_2) = 4,1$ On calcule les deux Centres

$D(x_5, M_1) = 4$ | $D(x_5, M_2) = 3,5$ $M_1(0,66, 1) / M_2(1,5, 1)$

$x_1(0; 3) \quad x_2(0; 0) \quad x_3(2; 0) \quad x_4(6; 0) \quad x_5(6; 8)$

$M_1(0.6; 1) \quad M_2(8.1; 1)$

$$\begin{array}{l} D(x_1, M_1) = 2.66 \\ D(x_2, M_1) = 1.66 \\ D(x_3, M_1) = 8.34 \\ D(x_4, M_1) = 6.34 \\ D(x_5, M_1) = 1.34 \end{array} \quad \begin{array}{l} D(x_2, M_2) = 7.1 \\ D(x_3, M_2) = 6.1 \\ D(x_4, M_2) = 4.1 \\ D(x_5, M_2) = 1.1 \end{array}$$

$C_1(x_1, x_2, x_3) \quad C_2(x_4, x_5)$

Stabilité : l'algorithme s'arrête

énorme $\rightarrow$ très
gigantesque

Normalisation des données :

Problème : attributs des petites valeurs
" " " des grandes valeurs

L'idée = rendre tous les attributs "équilibrés"
- elle réduit les grandes valeurs
et remet tous dans une même échelle
"équilibrer les attributs"

Calcul l'écart absolu moyen :

$$Sg = \frac{1}{n} |x_{1g} - m_g| + |x_{2g} - m_g| + \dots + |x_{ng} - m_g|$$

$$\text{où : } m_g = \frac{1}{n} (x_1 + \dots + x_{ng})$$

mesure standardisée :

$$\text{valeur} \leftarrow z_{ij} = \frac{x_{ij} - m_j}{Sg}$$

(2)

Calcul de distance entre deux clusters :

• Single link : Prend la plus petite distance entre deux clusters

• Complete link : Prend la plus grande distance

• Average : la moyenne de toutes les distances

Centroid : Calcul du centre de chaque cluster $\rightarrow$ distance entre centres

DBSCAN

• Regroupement basé sur la densité avec gestion de bruit

Paramètre : R = Rayon $\&$ M_{inP} : Nombre M de voisins
 $\downarrow$
nombre minimum

La distance maximale
Pour considérer deux
points comme voisins

Pour considérer une région
dense

Type de point dans DBSCAN :

↳ Point central : il possède au moins M_{inP} voisins dans son Rayon R

↳ Point bordure : Possède moins de M_{inP} voisins
Mais est proche d'un point central

central $\rightarrow$ point $\rightarrow$ proche
↳ : $\rightarrow$ point central $\Rightarrow$ proche
alors Bordure

↳ bruit : isolé
En dehors des régions denses

$$x_1(0,2) \quad \mu_1(0,75,0) \quad \mu_2(1,1)$$

$$D(x_1, \mu_1) = 2,75 \leftarrow \text{Dis Min}$$

$$D(x_1, \mu_2) = 6$$

$$D(\mu_1, \mu_2) = 1,25$$

On regroupe $x_1, \mu_1, \mu_3(0,38,1)$


$$\mu_2(1,1) \quad \mu_3(0,38,1)$$

$$D(\mu_2, \mu_3) = 1,62$$

Regrouper (μ_1, μ_2)

$$\mu_4 = (2,69, 1)$$

Dendrogramme:



Ex: Hierarchique

- $x_1(0,2); x_2(0,0); x_3(1,5,0); x_4(1,0); x_5(1,2)$
- Algorithme clustering Hierarchique ascendant + distance Cityblock

Calculer des distance $D(x_i, x_j) = |x_i - x_j|$

$$D(x_1, x_2) = |0 - 0| + |2 - 0| = 2$$

$$D(x_1, x_3) = 3,5$$

$$D(x_1, x_4) = 7$$

$$D(x_1, x_5) = 5$$

$$D(x_2, x_3) = 1,5 \leftarrow \text{Distance minimale}$$

$$D(x_2, x_4) = 5$$

$$D(x_2, x_5) = 7$$

$$D(x_3, x_4) = 3,5$$

$$D(x_3, x_5) = 1,5$$

$$D(x_4, x_5) = 2$$

alors on regroupe x_2, x_3 et on forme le premier Cluster

$$\mu_1 \left(\frac{0+1,5}{2}, \frac{0+0}{2} \right) \Rightarrow \mu_1(0,75,0) \text{ centre des } x_2 \text{ et } x_3$$

$$x_1(0,2) \quad \mu_1(0,75,0) \quad \mu_3(1,0); x_4(1,2)$$

$$D(x_1, x_4) = 7 \quad \text{alors on regroupe } (x_4, x_5)$$

$$D(x_4, x_5) = 5 \quad \mu_2(1,1)$$

$$D(x_1, \mu_1) = 2,75$$

$$D(\mu_1, \mu_2) = 4,25$$

$$D(\mu_1, \mu_3) = 6,25$$

$$D(x_4, x_5) = 2 \leftarrow \text{Distance Min}$$

(2)

(2)

(1)