
2023/2024

1) Quels sont les critères de robustesse de l'approche de clustering?

Stabilité : Le clustering doit produire des résultats similaires sur des échantillons différents des mêmes données

- **Résistance au bruit** : Le clustering doit être peu sensible aux données aberrantes ou au bruit
- **Scalabilité** : La méthode doit pouvoir gérer des volumes de données importants
- **Consistance** : Les résultats doivent être cohérents avec différentes initialisations ou paramètres similaires
- **Reproductibilité** : Doit produire des résultats similaires sur les mêmes données avec les mêmes paramètres
- **Interprétabilité** : Les clusters obtenus doivent avoir une signification claire et interprétable

2) Quelles sont les avantages et les inconvénients de remplacer le support par le lift dans une approche d'extraction d'itemsets fréquents?

Avantages :

- Meilleure détection des corrélations intéressantes entre items (le lift mesure la dépendance statistique)
- Réduit le biais vers les items fréquents (qui dominent avec le support classique)
- Permet de trouver des associations significatives même pour des items peu fréquents
- Plus sensible aux relations non aléatoires entre items

Inconvénients :

- Calcul plus complexe (nécessite de connaître les supports individuels)
- Peut générer beaucoup plus de règles, y compris certaines non pertinentes
- Plus difficile à interpréter pour les non-experts
- Moins efficace pour les items très fréquents (peut masquer certaines associations évidentes)
- Nécessite un seuil supplémentaire (minimum lift) à déterminer

3) Si on change le seuil de support minimal (Minsup), quelle sont les critères que doit respecter le nouveau critère d'élagage pour l'extraction d'itemsets fréquents?

Le nouveau critère d'élagage doit respecter :

- **Propriété d'anti-monotonie** : Si un itemset n'est pas fréquent, aucun de ses sur-ensembles ne peut l'être
- **Compatibilité avec la mesure de support** : Doit permettre un calcul efficace du support des candidats

- **Efficacité** : Doit permettre d'éliminer un maximum d'itemsets non fréquents tôt dans le processus
- **Complétude** : Doit garantir qu'aucun itemset fréquent n'est éliminé prématurément
- **Adaptabilité** : Doit fonctionner avec différents niveaux de Minsup sans modification structurelle

4) Quelles sont les points communs et les différences entre l'algorithme K-means et DBSCAN?

Points communs :

- Les deux sont des algorithmes de clustering non supervisé
- Visent à regrouper des données similaires
- Peuvent être utilisés pour diverses applications
- Sensibles au choix des paramètres (k pour K-means, ϵ et minPts pour DBSCAN)

Différences :

Critère	K-means	DBSCAN
Type de clusters	Sphériques, de taille similaire	Arbitraires, de densité
Nombre clusters	Fixe (k)	Déterminé automatiquement
Bruit	Pas de gestion explicite	Gère bien les points aberrants
Complexité	$O(n \cdot k \cdot i)$	$O(n \log n)$ avec index spatial
Paramètres	Nombre k de clusters	Rayon ϵ et minPts
Formes clusters	Limité aux formes convexes	Peut trouver des formes complexes
Initialisation	Sensible aux centroïdes initiaux	Pas d'initialisation nécessaire
Données	Nécessite des données numériques	Fonctionne avec données spatiales
Hiérarchie	Non	Peut détecter une hiérarchie

Ratt 2022/2023

1) Quelles sont les causes de la sur-informations et de la sous-information?

Sur-information :

- Données redondantes ou dupliquées
- Collecte excessive d'infos non pertinentes
- Multiplicité des sources

Sous-information :

- Données manquantes/incomplètes
- Systèmes de collecte défaillants
- Restrictions d'accès

2) Quelle est l'intérêt de l'étape de prétraitement des données dans une approche data mining. Justifiez.

Intérêt principal :

- Améliore la qualité des données (nettoyage, normalisation)
- Optimise les performances des algorithmes
- Rend les résultats plus fiables et interprétables

Justification : Essentiel pour obtenir des analyses précises et exploitables.

3) Dans quel cas l'extraction des itemsets fréquents est plus intéressante que l'extraction des itemsets fermés fréquents?

Quand on a besoin :

- De tous les sous-ensembles fréquents (pas juste les maximaux)
- Pour calculer des métriques précises sur tous les itemsets
- Dans des petits datasets où la redondance est acceptable

4) Quelles sont les conditions à satisfaire pour pouvoir considérer qu'une règle d'association acceptée est intéressante?

Doit avoir :

- Support et confiance élevés
- Lift > 1 (corrélation positive)
- Utilité pratique

- Nouveauté
 - Significativité statistique
-

2020/2021

1) Quels sont les facteurs qui influent sur les performances des algorithmes de clustering?

Facteurs clés :

- Taille et dimensionnalité des données
- Choix des paramètres (k , ϵ , minPts)
- Distribution des données (groupements naturels)
- Présence de bruit/outliers
- Métrique de similarité utilisée
- Complexité algorithmique

2) Quelle est l'approche d'extraction des règles d'association la plus adaptée dans le cas d'un contexte dense et dans le cas d'un contexte épars? Justifiez.

Contexte dense (peu d'items, forte corrélation) :

- **Algorithme :** FP-Growth
- **Justification :** Exploite la compression FP-tree efficace pour motifs fréquents

Contexte épars (beaucoup d'items, faible corrélation) :

- **Algorithme :** Apriori
- **Justification :** L'élagage par propriété anti-monotone réduit efficacement l'espace de recherche

3) Quelles sont les limites des approches data mining?

Principales limites :

- Qualité dépendante des données d'entrée
- Problème de sur-ajustement (overfitting)
- Difficulté d'interprétation des résultats
- Consommation importante de ressources
- Risque de découvrir des motifs aléatoires
- Biais potentiels dans les données

4) Quels sont les facteurs qui influent sur les performances des algorithmes des itemsets fréquents? Justifiez.

Facteurs impactants :

- **Seuil de support** : Plus minsup est bas, plus l'exécution est longue
- **Taille moyenne des transactions** : Impacte directement le nombre de combinaisons
- **Nombre d'items uniques** : Augmente exponentiellement l'espace de recherche
- **Corrélation entre items** : Affecte l'efficacité de l'élagage
- **Approche algorithmique** : FP-Growth > Apriori pour datasets denses

Justification : Ces facteurs déterminent la taille de l'espace de recherche et l'efficacité des techniques d'élagage.

2018/2019

1) Quelles sont les limites techniques du data mining?

Limites principales :

- Problèmes de qualité des données (bruit, incomplétude)
- Difficulté de traitement des données volumineuses (Big Data)
- Complexité algorithmique élevée pour certains modèles
- Limitations dans l'interprétation des résultats
- Sensibilité aux paramètres et configurations
- Difficulté à gérer les données en temps réel

2) Parmi les approches d'extraction des itemsets étudiées, laquelle est la plus adaptée dans le cas d'un contexte dense et dans le cas d'un contexte épars? Justifiez.

Contexte dense :

- **Algorithme** : FP-Growth
- **Justification** : Construction efficace d'arbres de motifs fréquents grâce à la compression FP-tree

Contexte épars :

- **Algorithme** : Apriori avec améliorations (Partition, Sampling)
- **Justification** : L'élagage par support minimum est efficace dans les données peu corrélées

3) Si on considère, dans une approche d'extraction de règles d'association, que chaque item possède un poids représentant son importance, donnez la valeur de calcul du support?

Formule du support pondéré :

##Support pondéré(T) = $\sum \text{poids}(\text{item})$ pour tous les items $\in T$ / $\sum$ poids totaux possibles

où T est une transaction et $\text{poids}(\text{item}) \in [0,1]$

4) Pour une classification supervisée, quand dit-on qu'on a un phénomène de sur-apprentissage?

Définition du sur-apprentissage :

Lorsque le modèle :

1. Obient d'excellentes performances sur les données d'entrainement
2. Mais de mauvaises performances sur des données nouvelles (test)
3. A appris le bruit et les spécificités du jeu d'entrainement
4. Montre une variance élevée et un biais faible

2017/2018

1) La distance choisie influence-t-elle le résultat d'une approche de clustering ?

Oui, absolument

La métrique de distance impacte directement :

- La forme des clusters obtenus
- L'affectation des points aux clusters
- La performance globale du clustering

Exemples :

- Euclidienne : favorise des clusters sphériques
- Manhattan (city block) : moins sensible aux outliers
- Cosinus : idéale pour données textuelles

2) Quel est l'avantage et l'inconvénient majeur du clustering incrémental ?

Avantage principal :

- Traitement des flux de données en temps réel
- Pas besoin de tout re-calculer quand de nouvelles données arrivent

Inconvénient majeur :

- Sensibilité à l'ordre d'arrivée des données
- Risque de convergence vers des solutions sous-optimales

3) Calcul du support pondéré pour des règles d'association

Formule :

Copy

Download

$\text{Support_pondéré}(\text{itemset}) = \sum \text{poids}(\text{items}) / \sum \text{poids_max_possible}$

Où :

- $\text{poids}(\text{items})$ = somme des poids des items de l'itemset
- $\text{poids_max_possible}$ = somme des poids de tous les items existants

Exemple :

Pour un itemset {A,B} avec $\text{poids}(A)=0.3$, $\text{poids}(B)=0.5$ et $\text{poids totaux}=2.0$:

$\text{Support_pondéré} = (0.3 + 0.5) / 2.0 = 0.4$ (40%)

2016/2017

1) Quel est l'intérêt de standardiser les données?

Principaux avantages :

- Permet une comparaison équitable entre variables de différentes échelles
- Améliore la performance des algorithmes sensibles aux distances (k-means, PCA)
- Accélère la convergence des algorithmes d'optimisation
- Réduit le biais des variables à large amplitude

2) Dans quel cas l'extraction des itemsets fréquents est plus intéressante que l'extraction des itemsets fermés fréquents?

Cas favorables aux itemsets fréquents classiques :

- Quand on a besoin de tous les sous-ensembles fréquents pour des analyses spécifiques
- Pour calculer des métriques précises sur tous les itemsets (pas seulement maximaux)
- Dans les petites bases où la redondance n'est pas problématique
- Lorsqu'on veut générer des règles avec conséquences multiples

3) Quelle est la différence entre donnée, information et connaissance?

Donnée :

- Valeur brute, fait observé (ex: "25°C")

Information :

- Donnée contextualisée (ex: "Température actuelle: 25°C")

Connaissance :

- Information interprétée et utile pour l'action (ex: "Si température > 20°C, réduire le chauffage")
-

2015/2016

1) Points à améliorer dans K-means (classification non supervisée)

Principales limitations et améliorations possibles :

- **Sensibilité à l'initialisation** → Utiliser K-means++
- **Nombre de clusters fixe** → Méthodes elbow/silhouette pour déterminer k optimal
- **Clusters sphériques uniquement** → Variantes spectrales ou kernel K-means
- **Sensibilité aux outliers** → K-medoids plus robuste
- **Problème avec données déséquilibrées** → Ponderations adaptatives

2) Cas où l'extraction des itemsets maximaux est intéressante

Situations privilégiées :

- Grands datasets avec forte combinatoire
- Quand seuls les motifs les plus longs sont pertinents
- Pour réduire la redondance dans les résultats
- Applications où seules les combinaisons complètes importent
- Optimisation des performances (moins d'itemsets à stocker)

3) Conditions pour calculer la confiance d'une règle d'association

Prérequis indispensables :

1. $\text{Support}(X \cup Y)$ doit être > 0
2. $\text{Support}(X)$ doit être > 0
3. Base de transactions suffisamment large
4. Seuil de support minimum atteint
5. Itemsets fréquents déjà extraits

Formule : $\text{Confiance}(X \rightarrow Y) = \text{Support}(X \cup Y) / \text{Support}(X)$

4) Causes de la sur-information et sous-information

Sur-information :

- Collecte excessive de données redondantes

- Multiplicité des sources non synchronisées
- Stockage d'historiques non nécessaires
- Manque de politique de purge

Sous-information :

- Capteurs défectueux ou absents
- Restrictions d'accès abusives
- Biais dans la collecte
- Granularité temporelle/spatiale insuffisante
- Problèmes d'intégration système